Tema 1

Optimización

Conceptos previos

Índice

Esquema 2

Ideas clave 3

1.1 Introducción y objetivos 3

1.2 Objetivos 4

1.3 Introducción informal a la optimización matemática . . 5

1.4 Definiciones básicas 9

1.5 Clasificación de problemas de optimización 16

1.6 Métodos heurísticos 20

1.7 Teoría de control y optimización 22

Esquema

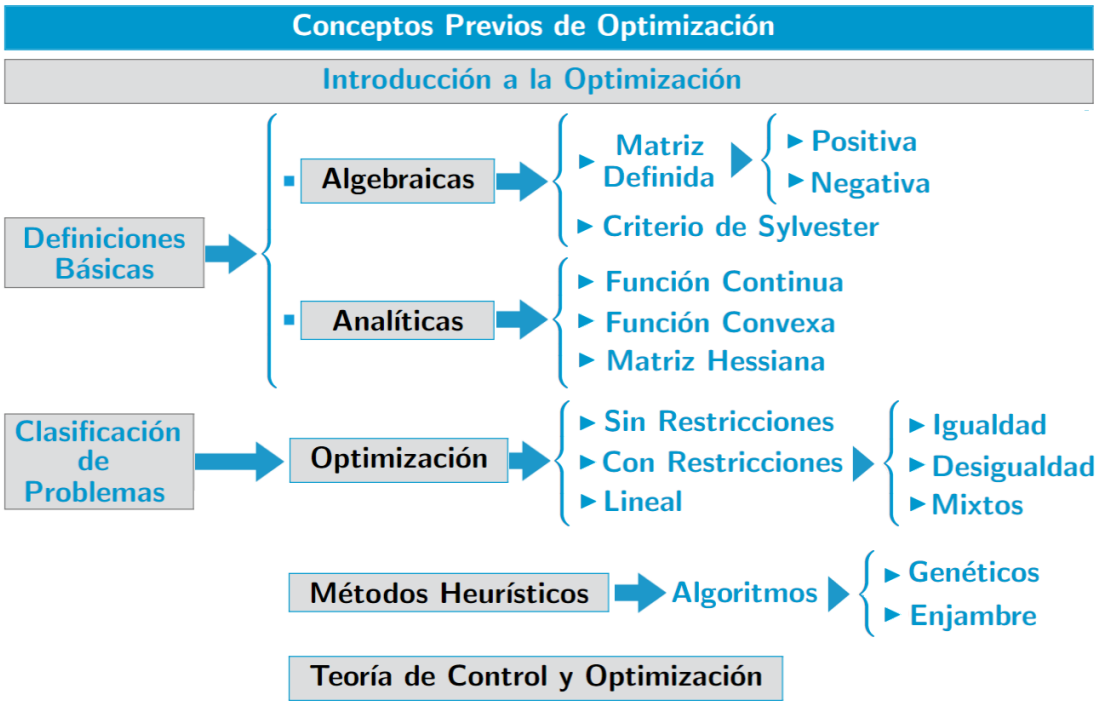
Conceptos Previos de Optimización
Introducción a la Optimización
Definiciones Básicas
Algebraicas
Matriz Definida
Positiva
Negativa
Criterio de Sylvester
Analíticas
Función Continua
Función Convexa
Matriz Hessiana
Clasificación de Problemas
Optimización
Sin Restricciones
Con Restricciones
Igualdad
Desigualdad
Mixtos
Lineal
Métodos Heurísticos
Algoritmos
Genéticos
Enjambre
Teoría de Control y Optimización

Ideas clave

1.1 Introducción y objetivos

Éste es un curso introductorio a la teoría de optimización matemática i.e. el conjunto de técnicas matemáticas que permiten encontrar la mejor solución (bajo algún criterio prefijado) a un problema dado.

En este primer tema, se repasarán algunos conceptos que conformarán una base con la que avanzar a través del resto de temas resulte más sencillo y eficiente. El curso, está fuertemente enfocado al cálculo numérico y la implementación de algoritmos que, en su mayoría, se realizarán en Matlab sin desestimar alguna otra posibilidad. Ahora bien, la teoría como en todo proceso de aprendizaje, debe ser considerada y empleada correctamente para así comprender los objetos de estudio y con ello, facilitar su implementación. Es por ello, que se aprovechará este primer tema para introducir algunos resultados teóricos fundamentales que justificarán el enfoque más algorítmico de los siguientes temas, que casi en su totalidad se presentan sin demostración, situación que el lector puede complementar de forma autónoma, en caso de resultar necesario.

El tema, se abre con una introducción informal (no demasiado rigurosa) al problema de optimización de funciones continuas. El propósito de esta segunda sección es poner en contexto y ejemplificar ciertos aspectos del problema de optimización. Ya desde esta introducción informal, se observa una fuerte relación entre los problemas de optimización de funciones continuas y el cálculo matemático.

La tercera sección, consiste en un conjunto de definiciones y resultados básicos, donde se proveen conceptos y herramientas necesarias para encarar, con ciertas garantías,

un subconjunto amplio de problemas de optimización (de funciones continuas) conocido como **optimización convexa**. En esta sección, esencialmente serán repasados conceptos y resultados de cursos de álgebra lineal y cálculo multivariante. Se finalizará la sección, con un resultado sobre óptimos locales de funciones de varias variables.

Seguidamente se encuentra una sección más general, en la que se formula un problema de optimización en forma general. Dependiendo de los atributos específicos de los elementos de la formulación, es posible establecer una clasificación de los distintos tipos de problema (problema sin restricciones, con restricciones de igualdad, etc.). Se dará el teorema fundamental de la optimización convexa, es decir, se establecen condiciones suficientes para la existencia de óptimos globales en problemas de optimización. Además, se incluirá una breve descripción de problemas no continuos, partiendo del problema general que ya se ha estudiado, pero admitiendo que el conjunto de posibles soluciones sea discreto.

Al final, se hallarán dos secciones que describen situaciones que perfilan hacia el final del curso (temas 8, 9 y 10). Se realizará un breve resumen de la idea de método heurístico (o metaheurístico), y de este modo, será posible contextualizar y justificar los temas 8 y 9. De manera similar, la última sección es una breve introducción a la teoría de control, que podría establecerse como una de las aplicaciones más importantes de la teoría de optimización.

1.2 Objetivos

Se podrían enunciar tres objetivos fundamentales:

- Fijar bases teóricas para el correcto estudio de un curso inicial de optimización y con ello, estimular el repaso de algunos resultados.
- Exponer ejemplos sencillos, que permitan crear una idea completa del contenido del curso.
- Explorar intuitivamente el amplio espectro de la optimización matemática.

1.3 Introducción informal a la optimización matemática

La **optimización matemática**, grosso modo, consiste en encontrar, de entre un conjunto de elementos, aquél que sea el mejor bajo algún criterio prefijado. Esta definición, por ser poco concreta, no arroja demasiada luz sobre los aspectos concretos que forman la disciplina de la teoría de optimización. Lo que sí hace, es dar una idea del amplio espectro de problemas que pueden ser etiquetados como problemas de optimización y, por ende, el amplio abanico de aplicaciones que uno puede esperar abordar, con técnicas que resuelvan este tipo de problemas.

Quizá, tratar de hallar el mejor de alguna selección puede inducir de manera directa en el lector a una búsqueda incesante del mayor o del menor valor que se pueda alcanzar en un determinado proceso. En principio, esto es así, aunque resulta importante de destacar que posiblemente nos enfrentemos a situaciones donde se declarará solución a un elemento que el problema en sí mismo no le otorga la categoría del mejor, pero que se adapta a ciertas necesidades.

Posiblemente, el ejemplo más sencillo de un problema de optimización es el de minimizar (o maximizar) una función de variable real. Por ejemplo,

$$\text{minimizar} \quad x^2 \ , \ \ x \in \mathbb{R}.$$

Este problema se puede resolver simplemente observando la gráfica de la función. En efecto, $f(x) = x^2$ es una función no negativa que toma el valor 0 cuando $x = 0$. Esto es, $x = 0$ es el elemento de la recta real para el cual, la función $f(x) = x^2$ tiene el valor más pequeño. En consecuencia, la respuesta del problema depende de dos factores fundamentales, en primer lugar, la función x^2, como es obvio, y en segundo lugar del rango en que se permite tomar valores a la variable x.

En efecto, si se cambia el problema anterior por:

$$\text{minimizar} \quad x^2, \quad x \in (0, \infty).$$

Entonces, la respuesta anterior deja de ser cierta, a x no se le permite tomar el valor 0. Es más, dada la naturaleza abierta del dominio considerado, no existirá un valor de x, para el que se alcance el valor mínimo, pues, para todo número $x_1 \in (0, \infty)$ existe otro número $x_2 \in (0, \infty)$, tal que $f(x_1) > f(x_2)$.

Finalmente, es posible considerar un problema mucho más general. Sea $S \subseteq \mathbb{R}^n$ un conjunto y f una función definida en S que toma valores reales. Entonces, al considerar el problema:

$$\text{minimizar} \quad f(\mathbf{x}) \, , \, \mathbf{x} \in S \tag{1}$$

A priori, no es posible saber, si el problema tiene solución o si esta en caso de existir es única. Sin embargo, existen condiciones bastante generales en los que es posible asegurar la existencia de una solución. Para ello, recordamos el teorema de Weierstrass.

Teorema 1: Weierstrass

Si f es una función continua y S es un compacto, existe $\mathbf{x}^* \in S$, tal que:

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) \text{ , para todo } \mathbf{x} \in S$$

□

El teorema de Weierstrass, afirma que existe una solución al problema de optimización (1) siempre que f sea una función continua y S sea un conjunto compacto (i.e. un conjunto cerrado y acotado). En teoría de optimización, a la función f se le llama **función objetivo**.

Considere ahora un problema distinto. Supongamos que queremos encontrar el punto de la recta $\ell := ax + by = c$ que está más cercano a un punto (x_0, y_0) dado. En términos de que la función raíz cuadrada es creciente y por ende, sus valores extremos los obtiene en su argumento, es posible escribir este problema de minimización de una

distancia, como:

$$\begin{cases} \text{minimizar} & (x-x_0)^2+(y-y_0)^2 \\ \text{Sujeto a:} & ax+by=c \end{cases}$$

Observe que losrequerimientos han cambiado. En efecto, se debe minimizar la función $f(x,y) = (x-x_0)^2+(y-y_0)^2$, pero no vale cualquier solución. El óptimo ha de pertenecer a la recta dada.

En este caso, aunque la función objetivo es una función de dos variables, el conjunto de soluciones admisibles es una recta, esto es, una variedad unidimensional del plano. En consecuencia, la condición $ax+by=c$ se denomina **restricción**. El problema de encontrar el punto de una recta que está más cercano un punto dado es un **problema de optimización con restricciones**.

Para resolver este problema, se escribe $x=(c-by)/a$ (asumiendo que $a \neq 0$) y en este sentido, el problema anterior es equivalente al siguiente problema unidimensional sin restricciones:

$$\text{minimizar} \quad \left(\left(\frac{c-by}{a}\right)^2 - x_0\right)^2 + (y-y_0)^2$$

Es decir, a veces, es posible reescribir ciertos problemas con restricciones como problemas sin restricciones definidos en espacios de dimensión menor.

Ejemplo 1. Reducción a Optimización Unidimensional sin Restricciones

Determine el punto de la recta $x+y=2$ más cercano a $(2,2)$.

El problema escrito con restricciones es:

$$\begin{cases} \text{minimizar} & (x-2)^2+(y-2)^2 \\ \text{Sujeto a:} & x+y=2 \end{cases}$$

De donde, $\boxed{x = 2 - y}$. Luego, es posible reescribir el problema como:

$$\text{minimizar} \quad y^2 - 4y + 4\,,\; y \in \mathbb{R}$$

En este caso, el valor mínimo de esta parábola es $y = 1$. Utilizando el hecho de que $x = 2 - y$, se tiene que: $x = 1$. Por lo tanto, la solución del problema es el punto $(1, 1)$.

Siguiendo con el ejemplo anterior, este se puede escribir de la siguiente forma:

$$\begin{cases} \text{minimizar} & x \\ \text{Sujeto a:} & x^2 \leq y \\ & x^2 + y^2 \leq 2 \end{cases}$$

Se nota que este problema es equivalente al que ha sido resuelto en el **Ejemplo 1**. En una forma equivalente del problema, donde se simplifica la función objetivo (ahora es una función lineal) a cambio de complicar las restricciones. En principio, esto establece que la formulación de un problema de optimización no es única. En efecto, geométricamente el **Ejemplo 1**, se puede plantear que de todas las formas posibles que hay de conectar al punto $A(2, 2)$ con la recta $x + y = 2$, la longitud más corta es $d = \sqrt{2}$ y se alcanza en el punto $B(1, 1)$, como se ilustra en la Figura 1 y cuya distancia se puede corroborar con la fórmula de la distancia de un punto $P(x_0, y_0)$ a una recta dada en forma general: $\ell := ax + by + c = 0$, descrita de la forma:

$$d = d(P, \ell) = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}} \Longrightarrow d = \frac{|1 \cdot 2 + 1 \cdot 2 - 2|}{\sqrt{1^2 + 1^2}} = \frac{2}{\sqrt{2}} = \sqrt{2}$$

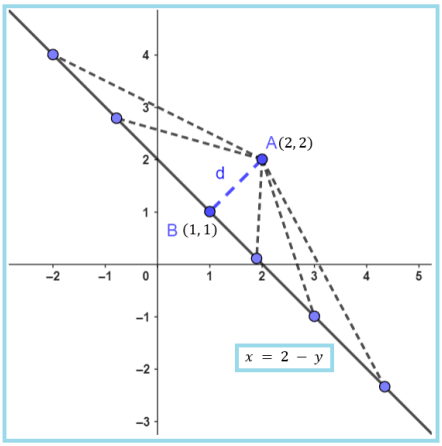

Figura 1: Distancia del punto $A(2, 2)$ a la recta $\ell := x + y = 2$

La escogencia de una solución óptima o el valor donde se alcanza un extremo, de la cantidad infinita de soluciones posibles , es lo que convierte a un problema como este, en un problema de optimización.

Hasta este momento, se han considerado solamente problemas de minimización, esto es, preguntarse si una función tiene un mínimo. El caso de los problemas de maximización es totalmente análogo. En efecto, todo problema de maximización se puede reducir a un problema de minimización cambiando el signo a la función objetivo. En particular, si x^* realiza un mínimo de f, entonces realiza un máximo de $-f$. En este curso se considerarán, con propósitos metodológicos, casi siempre problemas de minimización.

1.4 Definiciones básicas

En la sección previa, se han introducido, de manera informal, ciertos aspectos básicos de la teoría de optimización. En esta sección, se presentará una versión más formal (y más general).
Considere en principio algunas definiciones y propiedades relativas al álgebra lineal. Sea M una matriz $n \times n$. Entonces:

- Se dirá que M es **invertible**, si existe una matriz M^{-1}, tal que:

$$M \cdot M^{-1} = M^{-1} \cdot M = I.$$

  Por otra parte, una matriz es invertible, si y solo si su determinante es distinto de Cero. Además, se cumple que:

$$\det(M^{-1}) = \det(M)^{-1}.$$

- Se dirá que M es **simétrica**, si $M^t = M$.

- Se dirá que M es **definida negativa** (**positiva**), si $x^t M x < 0$ ($x^t M x > 0$) para todo

$x \in \mathbb{R}^n$ no nulo. En el caso que las desigualdades no sean estrictas, se utiliza la nomenclatura *semidefinida negativa* y *semidefinida positiva*.

- Se dice que $\lambda \in \mathbb{C}$ es un **autovalor** de **autovector** v si $Mv = \lambda v$.

- Las matrices definidas negativas (positivas), son exactamente aquellas que tienen todos sus autovalores negativos (positivos). Si los autovalores son no positivos (no negativos), entonces la matriz es semidefinida negativa (positiva).

- Suponga que M es una matriz $n \times n$. Un menor de orden $k \leq n$ es el determinante de la submatriz resultante al eliminar $n - k$ filas y $n - k$ columnas. Dado $k \in \{1, 2, \ldots, n-1\}$, el menor principal de orden k es el determinante de la matriz obtenida al eliminar las $n-k$ últimas filas y las $n-k$ últimas columnas. Este menor se denotará por M_k.

- **Criterio de Sylvester:** M es definida positiva si y solo si todos los menores principales son positivos. Si, para $k \in \{1, 2, \ldots, n-1\}$, todos los menores son positivos y $M_n = 0$, entonces la matriz es semidefinida positiva. El criterio es un poco más complicado para el caso de matrices definidas negativas: M es definida negativa si y solo si $(-1)^k M_k > 0$. Si, para $k \in \{1, 2, \ldots, n-1\}$, $(-1)^k M_k > 0$ y $M_n = 0$, entonces la matriz es semidefinida negativa.

Ejemplo 2. Matrices - Definiciones de Álgebra Lineal

Se proporcionarán ejemplos de las definiciones anteriores:

1. La matriz

$$M = \begin{bmatrix} 1 & 2 \\ -1 & 2 \end{bmatrix},$$

es invertible. En efecto, si consideramos la matriz

$$M^{-1} = \begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ \frac{1}{4} & \frac{1}{4} \end{bmatrix},$$

ésta verifica la condición de inversa ($M \cdot M^{-1} = I$).

2. La matriz $M = \begin{bmatrix} 1 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 4 \end{bmatrix}$, es simétrica ya que verifica que $M^T = M$. ■

3. Considere una matriz 2×2 genérica y simétrica:

$$M = \begin{bmatrix} a & b \\ b & c \end{bmatrix},$$

Dado $v = (x, y) \in \mathbb{R}^2$, la condición $v^T M v$ se escribe como:

$$ax^2 + 2bxy + cy^2.$$

Que en realidad corresponde a la expresión matricial:

$$v^T M v = [x \quad y] \begin{bmatrix} a & b \\ b & c \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

Se deben establecer condiciones sobre a, b y c, para asegurar que M sea definida negativa (positiva). En primer lugar, es de hacer notar que si $y = 0$, entonces: $v^T M v = ax^2$. En particular, una condición necesaria para que M sea definida negativa (positiva) es que $a < 0$ ($a > 0$). Supongamos que $y \neq 0$ y consideramos el cambio de variable $x = ty$. Ver que $v^T M v < 0$ (> 0) equivale a ver que la parábola:

$$f(t) = at^2 + 2bt + c < 0 \quad (> 0)$$

Si $a < 0$ y el valor en el que se alcanza el extremo relativo de la parábola ($x^* = \det(M)/a$) también lo es, entonces M será definida negativa. Análogamente, si $a > 0$ y el valor en el que se alcanza el extremo relativo son positivos, M será definida positiva. ■

4. El criterio de Sylvester no se puede generalizar trivialmente para matrices semidefinidas positivas o semidefinidas negativas. De hecho, para tal caso solamente se ha dado una condición suficiente. Por ejemplo, considere la siguiente

matriz:

$$M = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & \frac{1}{2} \end{bmatrix}.$$

El determinante de la matriz es nulo. Luego, el menor principal de orden 3 (el determinante de la matriz) es cero. El menor principal de orden 2 es:

$$\det \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = 0.$$

Mientras que el menor principal de orden 1 es $1 > 0$. En particular, se tiene una matriz cuyos menores principales son no negativos. Sin embargo, la matriz no es semidefinida positiva. En efecto, si se escoge $v = (1, 1-2)$, se tiene que $v^T M v = -2 < 0$. De hecho, puede comprobarse que esta matriztiene un autovalor nulo, otro positivo y otro negativo. En consecuencia, esta forma es indefinida. ■

Sea $\mathcal{U}$ un conjunto abierto de $\mathbb{R}^n$ y f una función definida en $\mathcal{U}$ que toma valores reales. Bajo estas condiciones, es recomendable recordar algunas definiciones básicas.

Definición 1

Sea $f : \mathcal{U} \longrightarrow \mathbb{R}$, con $\mathcal{U} \subseteq \mathbb{R}^n$ un conjunto abierto. Decimos que:

- f es continua en el punto $\mathbf{x}_0$ si, para todo $\varepsilon > 0$, existe $\delta > 0$ tal que, si $\|\mathbf{x} - \mathbf{x}_0\| < \delta$, entonces $|f(\mathbf{x}) - f(\mathbf{x}_0)| < \varepsilon$. Se dirá que f es continua en $\mathcal{U}$ si es continua para todo $\mathbf{x} \in \mathcal{U}$.
- f es una función Lipschitz, si existe $K > 0$ tal que:

$$|f(\mathbf{x}) - f(\mathbf{y})| \leq K\|\mathbf{x} - \mathbf{y}\|,$$

  para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$.
- Sean $\mathbf{x}_0, v \in \mathcal{U}$ con $\|v\| = 1$. La derivada de $f$en la dirección de v, se define

por:

$$\frac{\partial f}{\partial v}(\mathbf{x}_0) = \lim_{h \to 0} \frac{f(\mathbf{x}_0 + hv) - f(\mathbf{x}_0)}{h},$$

siempre y cuando el límite exista. . Esta expresión, también puede ser denotada por: $D_v f(\mathbf{x}_0$. En efecto, si la función f es diferenciable, esta derivada coincide con las derivadas parciales de la función. Si $v = e_i$, es un vector de la base canónica de $\mathbb{R}^n$, entonces se usará la notación:

$$\frac{\partial f}{\partial x_i}(\mathbf{x}_0) = \frac{\partial f}{\partial e_i}(\mathbf{x}_0) = D_{e_i} f(\mathbf{x}_0)$$

la cual se denomina **derivada parcial** de f con respecto de la variable x_i. Se dirá entonces, que la función es diferenciable si, para todo punto, existen todas las derivadas parciales y son continuas.

- A la función vectorial que actúa de en $\mathbb{R}^n$ conformada por las derivadas parciales, se le llama **gradiente** de f (y lo denotamos por ∇f). La definición proporcionada de derivada direccional y de derivada parcial, se puede generalizar fácilmente a funciones que toman valores en $\mathbb{R}^n$. Si el gradiente es una función diferenciable, entonces se dice que la función f es de clase $\mathcal{C}^2$ y, a la matriz diferencial de ∇f , se le denomina **matriz Hessiana** de f, que se suele denotar por H.

- Un punto $\mathbf{x}_0$ es un **mínimo local** de f si existe un $\delta > 0$, tal que $f(\mathbf{x}_0) \leq f(\mathbf{x})$ para todo $\mathbf{x} \in B_\delta(\mathbf{x}_0)$ (la bola con centro $\mathbf{x}_0$ y radio δ). Un punto $\mathbf{x}_0$ es un mínimo global si $f(\mathbf{x}_0) \leq f(\mathbf{x})$ para todo $\mathbf{x} \in \mathcal{U}$. La definición de máximo local y global es análoga.

- Si $\mathbf{x}_0 \in \mathcal{U}$ es tal que $\nabla f(\mathbf{x}_0) = \mathbf{0}$, entonces se dirá que se tiene un **punto crítico**, es decir un punto donde es posible se realice un extremo de f. A estos puntos, también se les conoce con el nombre de **puntos estacionarios**.

- Sea $\mathbf{x}_0$ un punto crítico de f. Suponga que existen vectores v y w tales que $t = 0$ realiza un mínimo local de la función unidimensional $f_v(t) = f(\mathbf{x}_0 + tv)$ y un máximo local de la función unidimensional $f_w(t) = f(\mathbf{x}_0 + tw)$. Entonces se dice que $\mathbf{x}_0$ es un **punto de silla**.

Adicionalmente, se dirá que el abierto $\mathcal{U}$ es **convexo** si para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, la cantidad $(1-t)\mathbf{x} + t\mathbf{y} \in \mathcal{U}$, para todo $t \in [0,1]$. Si la función f es diferenciable y $\mathcal{U}$ es convexo, se cumple el teorema del valor intermedio de Lagrange. Esto es, para todo par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, existe una cantidad $\alpha \in (0,1)$, tal que:

$$f(\mathbf{y}) - f(\mathbf{x}) = \langle \nabla f((1-\alpha)\mathbf{x} + \alpha\mathbf{y}), \mathbf{y} - \mathbf{x} \rangle.$$

Es de notar que la hipótesis sobre $\mathcal{U}$ (asumir que es convexo), es clave para poder evaluar la función f en $(1-\alpha)\mathbf{x} + \alpha\mathbf{y}$ en la identidad anterior. Por otro lado, si la función f verifica la siguiente desigualdad:

$$f((1-\alpha)\mathbf{x} + \alpha\mathbf{y}) \leq (1-\alpha)f(\mathbf{x}) + \alpha f(\mathbf{y})$$

para cualquier par $\mathbf{x}, \mathbf{y} \in \mathcal{U}$,se dirá que f es **convexa**. Gráficamente,

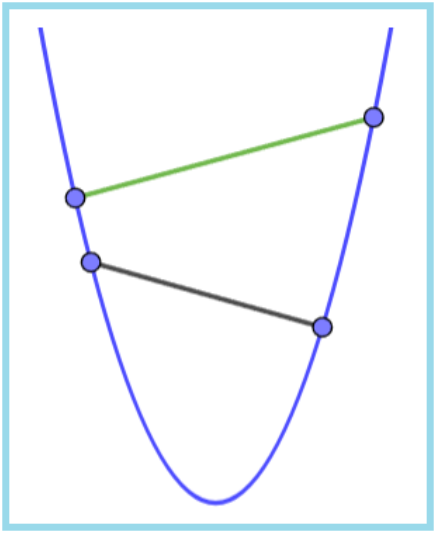

Figura 2: Observe que las combinaciones convexas de las alturas de la función superan a la función evaluada en las combinaciones convexas de los puntos.

Si $\mathbf{x}_0$ realiza un mínimo (máximo) de f entonces $\nabla f(\mathbf{x}_0) = \mathbf{0}$. Es decir, todo punto que realiza un óptimo es un punto crítico, pero el recíproco no es necesariamente cierto. Que el gradiente sea nulo es, entonces, una *condición necesaria* para la optimalidad. En este sentido, un resultado que proporciona una condición suficiente se puede observar en el siguiente teorema. Para ello, se consideran $\mathbf{x}, \mathbf{y} \in \mathcal{U}$, y se denotará por $[\mathbf{x}, \mathbf{y}]$ al subconjunto de $\mathcal{U}$ donde cada elemento se escribe de la forma: $z = (1-\alpha)\mathbf{x} + \alpha\mathbf{y}$, para algún $\alpha \in [0,1]$. Entonces,

Teorema 2

Sea $\mathcal{U}$ un abierto convexo y $f : \mathcal{U} \longrightarrow \mathbb{R}$ una función dos veces diferenciable. Suponga que x_0 es un punto crítico, entonces:

1. Si la matriz Hessiana $H(x_0)$ es definida positiva, entonces x_0 realiza un mínimo local.
2. Si la matriz Hessiana $H(x_0)$ de definida negativa, entonces x_0 realiza un máximo local.
3. Si la matriz Hessiana $H(x_0)$ es indefinida, entonces x_0 es un punto de silla. $\square$

Ejemplo 3.

onsidere la función dada por:

$$f(x, y, z) = x^2 + y^2 + z^2 - xy + yz - xz,$$

¿Qué hay de sus extremos relativos? Observe que ell gradiente de la función viene dado por

$$\nabla f(x, y, z) = (2x - y - z, 2y - x + z, 2z + y - x).$$

La única solución de la ecuación $\nabla f(x, y, z) = \mathbf{0}$ es $(x, y, z) = (0, 0, 0)$ (basta resolver el sistema de ecuaciones y usar, por ejemplo, la eliminación gaussiana). Tener gradiente nulo es una condición necesaria para ser un máximo o un mínimo. Esto es, el origen es el único candidato a extremo relativo. Si calculamos la matriz Hessiana en $(0, 0, 0)$, se obtiene:

$$Hf(0, 0, 0) = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & 1 \\ -1 & 1 & 2 \end{bmatrix}.$$

Los menores principales son

$$M_1 = 2, \quad M_2 = \det \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = 3, \quad M_3 = \det(Hf(0,0,0)) = 4.$$

En particular, todos los menores principales son estrictamente positivos. Esto significa que la matriz Hessiana es definida positiva y que, consecuentemente, el origen es un mínimo global de la función f (ya que es el único mínimo local).

Ejemplo 4.

Considere la función dada por:

$$f(x,y) = x^3 - 12xy + 8y^3.$$

El gradiente es:

$$\nabla f(x,y) = (3x^2 - 12y, -12x + 24y^2).$$

Existen dos puntos críticos, $(0,0)$ y $(2,1)$. La matriz Hessiana evaluada en el origen es:

$$Hf(0,0) = \begin{bmatrix} 0 & -12 \\ -12 & 0 \end{bmatrix}$$

Los autovalores de $Hf(0,0)$ son ± 12. Luego, $Hf(0,0)$ es indefinida y, por lo tanto, el origen es un punto de silla.

1.5 Clasificación de problemas de optimización

Considere ahora las funciones $G : \longrightarrow \mathbb{R}^m$ y $H : \mathcal{U} \longrightarrow \mathbb{R}^p$. En su forma más general, un problema de optimización tiene la forma:

$$\begin{cases} \text{minimizar} & f(\boldsymbol{x}) \\ \text{Sujeto a:} & G(\boldsymbol{x}) \leq \boldsymbol{0} \\ & H(\boldsymbol{x}) = \boldsymbol{0} \end{cases}$$

Aquí $G(\mathbf{x}) \leq \mathbf{0}$ se debe interpretar de la manera siguiente: Si se nombra $G(\mathbf{x}) = (G_1(\mathbf{x}), G_2(\mathbf{x}), \ldots, G_m(\mathbf{x}))$, entonces $G(\mathbf{x}) \leq \mathbf{0}$ ocurre cuando $G_i(\mathbf{x}) \leq 0$ para todo $i = 1, \ldots, m$. De manera similar se interpreta la condición $H(\mathbf{x}) = \mathbf{0}$. Hay otras formas generales de escribir problemas de optimización. Ésta se llama **forma estándar**.

A saber, tendremos una forma estándar de un problema lineal, si se busca de minimizar una función lineal en una o varias variables y con restricciones de igualdad también lineales. Se llama **conjunto de soluciones factibles (o admisibles)** al conjunto $\mathcal{F} \subseteq \mathcal{U}$, tal que $G(\mathbf{x}) \leq \mathbf{0}$ y $H(\mathbf{x}) = \mathbf{0}$ Es decir, el conjunto de puntos de $\mathbb{R}^n$ que cumplen con las restricciones. Se pueden clasificar en distintos tipos de problemas:

1. **Optimización sin restricciones:** : Un problema sin restricciones se puede interpretar como el problema anterior con G y H siendo funciones idénticamente nulas (o, si se quiere, tomando $m = p = 0$)
2. **Optimización con restricciones de desigualdad:** Se toma $m \neq 0$ y $p = 0$.
3. **Optimización con restricciones de igualdad:** Se toma $m = 0$ y $p \neq 0$.
4. **Optimización con restricciones mixtas:** Se considera a la función objetivo $c^T x$ como una función lineal.

Teorema 3: Condiciones de Karush-Kuhn-Tucker

Considere un problema de optimización en forma estándar con f, G y H funciones de clase $\mathcal{C}^1$. Sea

$$\mathcal{F} = \{\mathbf{x} \in \mathcal{U} \ : \ G(\mathbf{x}) \leq \mathbf{0}, \ H(\mathbf{x}) = \mathbf{0}\},$$

el conjunto de las soluciones factibles y $\mathbf{x}_0 \in \mathcal{F}$. Entonces:

1. Si f es una función convexa, $\mathcal{F}$ es un conjunto convexo y $\mathbf{x}_0$ realiza un mínimo local, entonces $\mathbf{x}_0$ realiza también un mínimo global.
2. Si f, G_i son funciones convexas y $H_j = A_j\mathbf{x} + b_j$, $j = 1, \ldots, p$ con A_j matrices $n \times p$ y $b_j \in \mathbb{R}^p$. Entonces dado $\mathbf{x}_0 \in \mathcal{F}$, si existen constantes $\mu_i \geq 0$,

$i = 1, \ldots, m$ y λ_j, $j = 1, \ldots, p$, tales que:

$$\nabla f(\mathbf{x}_0) = \sum_{i=1}^{m} \mu_i \nabla G_i(\mathbf{x}_0) + \sum_{j=1}^{p} \lambda_j \nabla H_j(\mathbf{x}_0),$$

y $\mu_i G_i(\mathbf{x}_0) = 0, \quad i = 1, \ldots, m,$. Entonces, $\mathbf{x}_0$ realiza un mínimo global. □

Optimización discreta

Generalizando un poco más la escritura del problema de optimización, es posible escribirlo de la forma:

$$\begin{cases} \min\limits_{\mathbf{x} \in \mathbb{X}} & f(\mathbf{x}) \\ \text{Sujeto a:} & \mathbf{x} \in \mathcal{F} \end{cases}$$

donde f es una función de un conjunto arbitrario que toma valores reales. En particular es admisible que $\mathbb{X}$ sea un conjunto discreto. Existen varias posibilidades comunes, tales como:

- $\mathbb{X} = \mathbb{R}^n$ (variables enteras) $\Longrightarrow \mathbb{X} = \mathbb{Z}^n$.
- $\mathbb{X} = \{0, 1\}^n$ (variables binarias).
- $\mathbb{X} = \mathbb{R}^n \times \mathbb{Z}^s \times \{0, 1\}^t$, posiblemente con $n = 0$, $s = 0$ o $t = 0$ (variables mixtas).

Ejemplo 5.

Suponga que, en una empresa, hay n trabajos a repartir entre n trabajadores. Suponga también que se pretende asignar a cada persona un solo trabajo. Suponga, además, que el costo de que el trabajador i realice el trabajo j es c_{ij}. El costo se puede asignar de distintas maneras, por ejemplo, puede ser el tiempo estimado que tardará el trabajador i en completar el trabajo j. Nos planteamos el problema de realizar la asignación de trabajos minimizando el costo. Para<ello, se toma $\mathbb{X} = \{0, 1\}^{n^2}$. Se establece por convención que $x_{ij} = 1$ si al trabajador i se le asigna el trabajo j y $x_{ij} = 0$ en otro caso. se tiene la restricción. Como a cada

trabajador se le puede asignar un sólo trabajo, se tiene la restricción:

$$\sum_{j=1}^{n} x_{ij} = 1, \quad i = 1, 2, \ldots, n.$$

Como todo trabajo tiene que ser asignado, se tiene la restricción:

$$\sum_{i=1}^{n} x_{ij} = 1, \quad j = 1, 2, \ldots, n.$$

El costo total de cada asignación será:

$$\sum_{j=1}^{n} \sum_{i=1}^{n} c_{ij} x_{ij}.$$

En particular, se puede escribir el problema de optimización como:

$$\begin{cases} \text{minimizar} & \displaystyle\sum_{j=1}^{n} \sum_{i=1}^{n} c_{ij} x_{ij} \\ \text{Sujeto a:} & \displaystyle\sum_{j=1}^{n} x_{ij} = 1, \quad j = 1, 2, \ldots, n \\ & \displaystyle\sum_{i=1}^{n} x_{ij} = 1, \quad i = 1, 2, \ldots, n \end{cases}$$

Se puede clasificar este problema como un problema lineal de variables binarias con restricciones.

1.6 Métodos heurísticos

En este curso se estudiarán varios métodos para calcular el óptimo de un problema. En muchos problemas, estos métodos no funcionan o tardan mucho en encontrar la solución. En tales casos, es posible utilizar métodos alternativos para encontrar una solución no necesariamente óptima pero sí suficientemente buena. Los temas 8 y 9 de este curso estarán dedicados a la optimización mediante técnicas metaheurísticas.

Los algoritmos metaheurísticos son, en el contexto de la optimización, técnicas de bús-

queda globales adecuadas para tratar problemas complicados. Ya se ha visto que, para tratar problemas de optimización continuos, son necesarias ciertas hipótesis sobre las funciones involucradas en el problema, tales como continuidad o en su defecto, condiciones de regularidad. Por ejemplo, como sucedía en el teorema de Karush-Kuhn-Tucker donde se pedían condiciones de regularidad sobre las funciones involucradas y también condiciones geométricas sobre el conjunto de soluciones factibles

Estas condiciones no siempre se dan en problemas derivados de situaciones reales. Es más, aunque se cumplan tales hipótesis, a veces, la dimensión del problema puede ser tan grande que evaluar la matriz Hessiana tiene un costo computacional prohibitivo. Más adelante,se verá que muchos de los algoritmos que se plantearán para la solución de problemas continuos tienen hipótesis extras para asegurar su convergencia. Todo este cúmulo de circunstancias justifican la implementación de métodos metaheurísticos.

El método heurístico más simple que uno puede imaginar es el método de ensayo y error: Esto es, verificar la condición de optimalidad para un conjunto de soluciones factibles (cuantas más soluciones factibles, mejor). Naturalmente, para tener unas mínimas garantías de éxito, hay que involucrar ideas un poco mássofisticadas. Los métodos resultantes de esas ideas tampoco suelen asegurar que su aplicación encontrará el óptimo global (en caso de existir). Una gran parte de los métodos metaheurísticos de alto nivel, dependen de ciertos parámetros aleatorios, lo que significa que la solución obtenida depende fuertemente de lamanera en que se generan ciertas variables aleatorias. De todos modos, los algoritmos son muy efectivos en una gran variedad de problemas y, además, son eficientes desde el punto de vista computacional.

La naturaleza es una constante fuente de inspiración para la ciencia y, particularmente, para los algoritmos de optimización metaheurística. En los temas 8 y 9 se estudiarán dos tipos de algoritmos que tienen una clara inspiración en procesos naturales:

- **Algoritmos genéticos:** La idea general de estos algoritmos es codificar toda solución factible como una cadena de símbolos (los genes). Por ejemplo, es posible

codificar un número real mediante su representación binaria. Luego, se decide una regla de apareamiento entre soluciones: Dos soluciones dan lugar a otra que se construye a partir de los genes de sus progenitoras (bajo la jerga de padres e hijos). En este apareamiento, se introducen pequeños cambios aleatorios y en general, se considera que las soluciones con mejor condición de optimalidad son las mejores adaptadas, aunque esto es posible decidirlo usando diversidad de condiciones de selección, de cruce, etc. Después de varias generaciones (o iterados del algoritmo), se toma como solución (sub) óptima aquella que esté mejor adaptada a la lógica del problema.

- **Algoritmos de enjambre:** Estos algoritmos pretenden emular el comportamiento de un enjambre (generalmente de insectos o partículas). En este caso, las soluciones se ven como elementos del enjambre que inician en una posición aleatoria y que se mueven con una cierta velocidad y dirección (gradiente). Las partículastienden a moverse hacia una solución óptima (local o global).

1.7 Teoría de control y optimización

Un **sistema dinámico** es un conjunto de estados y una regla que rige el cambio de estos estados a través del tiempo. Esta definición, un poco vaga, da a entender la gran cantidad de distintas problemas que uno puede modelar mediante sistemas dinámicos.

Por ejemplo, las ecuaciones diferenciales dan lugar a sistemas dinámicos continuos y son la basa para afrontar muchos de los problemas de la vida real (el caso paradigmático es la mecánica Newtoniana).

A un sistema dinámico que evoluciona de manera natural se le puede aplicar una fuerza externa (habitualmente controlado por el hombre) que altere sus propiedades. Esto se puede hacer para alcanzar diversos objetivos, por ejemplo: cambio de posición o velocidad, estabilizar o desestabilizar un equilibrio, etc.

Matemáticamente un sistema dinámico continuo con un problema de Cauchy asociado a una ecuación diferencial, esto es

$$\begin{cases} \dot{\mathbf{x}} = f(\mathbf{x}, t, \mathbf{c}) \\ \mathbf{x}(0) = \mathbf{x}_0 \end{cases}$$

Donde $t \in \mathbb{R}$ (puede suponerse positivo), $\mathbf{x} \in \mathbb{R}^n$ y $\mathbf{c} \in \mathbb{R}^m$ es una constante del sistema.

Introducir un **control**, en términos matemáticos, significa considerar una función $\boldsymbol{\alpha} : \mathbb{R} \longrightarrow \mathbb{R}^m$ y estudiar el problema

$$\begin{cases} \dot{\mathbf{x}} = f(\mathbf{x}, t, \boldsymbol{\alpha}) \\ \mathbf{x}(0) = \mathbf{x}_0 \end{cases}$$

Dado, t y $\mathbf{x}_0$, llamamos **respuesta del sistema** a la trayectoria $\mathbf{x}$ de la solución del problema de Cauchy anterior.

En principio, no se tiene ninguna pista acerca de qué control utilizar. El problema puede dar, de manera de natural, ciertas restricciones para el control de manera que, de todas las funciones $\boldsymbol{\alpha}$ posibles, solo un cierto subconjunto son controles factibles. Por otro el problema también induce, de manera natural, un funcional de costo, escrita como:

$$F(\boldsymbol{\alpha}) := \int_0^t r(\mathbf{x}(s), \boldsymbol{\alpha}(s))ds + g(\mathbf{x}(t)).$$

Aquí, se supone que las funciones r y g vienen dadas por el problema. La intención es minimizar el funcional F. Es de hacer notar que las soluciones, ahora, se eligen en un espacio de dimensión infinita. Esto implica que hay que utilizar técnicas avanzadas de *análisis funcional* y *cálculo variacional* para formular resultados sobre las condiciones necesarias y suficientes del problema. En conclusión, hay ciertos aspectos de esta teoría que puede salirse del espectro de necesidades iniciales de este curso.

Es posible entonces, escribir el problema de control como el siguiente problema de

optimización:

$$\min_{\boldsymbol{\alpha}} \quad F(\boldsymbol{\alpha}).$$

A partir de ahí, es posible realizar varias preguntas naturales:

- ¿Existe un control óptimo?
- ¿Es posible caracterizar su existencia?
- ¿Es posible calcularlo?