Optimización

Optimización sin restricciones

Índice

Esquema 2

Ideas clave 3

4.1 Introducción 3

4.2 Objetivos 4

4.3 El método de Newton 5

4.4 El método del gradiente 13

4.5 Métodos Cuasi-Newton 23

Esquema

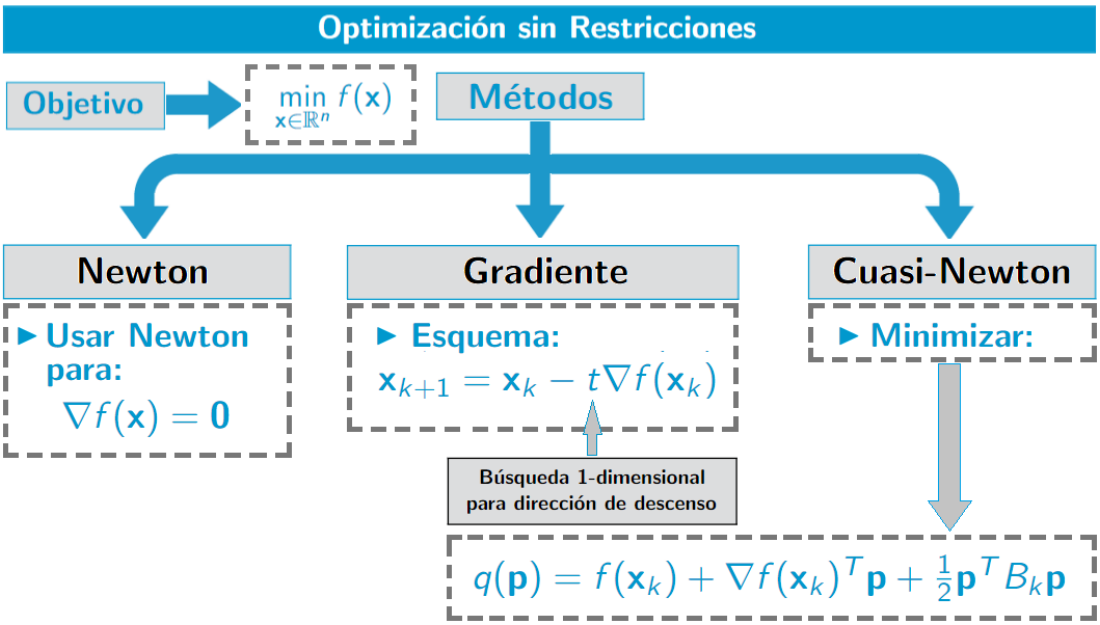
Optimización sin Restricciones
Objetivo
$\min_{\mathbf{x}\in\mathbb{R}^n} f(\mathbf{x})$
Métodos
Newton
Gradiente
Cuasi-Newton
▶ Usar Newton para:
$\nabla f(\mathbf{x}) = \mathbf{0}$
▶ Esquema:
$\mathbf{x}_{k+1} = \mathbf{x}_k - t\nabla f(\mathbf{x}_k)$
Búsqueda 1-dimensional para dirección de descenso
▶ Minimizar:
$q(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T\mathbf{p} + \frac{1}{2}\mathbf{p}^T B_k\mathbf{p}$

Ideas clave

4.1 Introducción

En este capítulo se estudiará el problema de optimización no lineal sin ninguna restricción, esto es:

$$\text{minimizar } f(\mathbf{x}),$$

con $f : \mathbb{R}^n \longrightarrow \mathbb{R}$. Los problemas de optimización sin restricciones aparecen de manera natural en los ajustes de datos, donde la función objetivo mide la diferencia entre el modelo y los datos reales. Además, los métodos para los problemas sin restricciones son la base para los métodos para los problemas con restricciones.

Se denotará por $\mathbf{x}^*$ al candidato a solución del problema de minimización, es decir al candidato a valor donde se alcanza el mínimo de la función f. Se puede notar que, a efectos prácticos, no tiene mucho sentido la pregunta de si ésta es una solución global, ya que eso requeriría calcular información de la función en cada punto de $\mathbb{R}^n$. De hecho, en general, si se tuviera una solución global de un problema de optimización, ni siquiera se podrías comprobar que lo es. Los candidatos a solución del problema realizarán mínimos locales. Esto es, un punto $\mathbf{x}_*$ que satisface la condición

$$f(\mathbf{x}^*) < f(\mathbf{x}) \quad \text{para todo } \mathbf{x} \text{ tal que } \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon,$$

donde $\varepsilon > 0$ es, típicamente, un número pequeño. Un minimizador local estricto es aquel que cumple:

$$f(\mathbf{x}^*) < f(\mathbf{x}) \quad \text{para todo } \mathbf{x} \text{ tal que } 0 < \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon.$$

Es posible que una función tenga un minimizador local y no global. También es posible

que no tenga ninguno de los dos o que tenga ambos. De hecho, cualquier tipo de combinación es posible. Evidentemente eso hace parecer que la condición de minimizador local no es mejor, a efectos prácticos, que la de minimizador global.

Si se sjupone además que la función tiene segunda derivada continua, es decir $f \in \mathcal{C}^2$, entonces se puede obtener una condición de optimalidad más práctica. Supongamos pues que $\mathbf{x}^*$ es un minimizador local de f y que f es de clase $\mathcal{C}^2$ en $\mathbf{x}^*$ y se considera el desarrollo en serie de Taylor de la función f alrededor de $\mathbf{x}^*$:

$$f(\mathbf{x}^* + \mathbf{p}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^t \mathbf{p} + \frac{1}{2}\mathbf{p}^t \nabla^2 f(\xi)\mathbf{p}.$$

Si $\mathbf{x}^*$ realiza un mínimo local de f (en general un extremo), entonces $\nabla f(\mathbf{x}^*) = \mathbf{0}$. Es decir, que la función tenga gradiente nulo en un punto, es una condición necesaria para que éste sea un mínimo local. Sin embargo, se nota que la condición no es suficiente, esto es, puede haber puntos en donde el gradiente de f se anula pero que no realizan mínimos (o máximos), es decir son puntos de silla o ensilladura. Para estar seguros de que un punto con derivada nula es un extremo relativo hay que examinar la segunda derivada. Para que $\mathbf{x}^*$ sea un minimizador local, debe suceder que $\nabla^2 f(\mathbf{x}^*)$ tiene que ser definido positivo. Esto es, para obtener una condición suficiente, tenemos que pedir que, además de tener gradiente nulo, tengamos segunda derivada definida positiva.

4.2 Objetivos

Para efectos del trabajo planteado, es necesario centrarse en tres objetivos específicos e importantes:

- Usar la versión del **Algoritmo de Newton**, para la exploración de extremos locales pero en el espacio n - dimensional.
- Explorar la segunda derivada, para determinar que en $\mathbf{x}^*$ se minimiza a f. Por tanto, debe ocurrir que $\nabla^2 f(\mathbf{x}^*)$ sea definido positivo.

- Mejorar el Método de Newton, disminuyendo costes y solicitando menos condiciones de regularidad (**Método del Gradiente**)

4.3 El método de Newton

El método de Newton es un método clásico para encontrar ceros de funciones no lineales, pero para utilizarlo en la optimización de funciones hay que aplicarlo al gradiente de la función. Esto es, hay que resolver la ecuación: $\nabla f(\mathbf{x}) = \mathbf{0}$.

Para ello, se considera inicialmente un campo escalar $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ de clase $\mathcal{C}^2$. Para estos efectos, resulta necesario calcular la matriz Jacobiana de ∇f, es decir $\nabla^2 f$ (**matriz Hessiana**). En consecuencia, el esquema numérico queda de la forma:

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k - [\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k)}$$

Forma habitual del método

Es habitual escribir el esquema del método de Newton como $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{p}_k$, donde $\mathbf{p}_k$ es la solución del sistema lineal:

$$\nabla^2 f(\mathbf{x}_k)\mathbf{p}_k = -\nabla f(\mathbf{x}_k).$$

Esta notación enfatiza el hecho de que, computacionalmente, es mucho más eficiente resolver el sistema que calcular la inversa de la segunda derivada (i.e. la matriz Hessiana). La fórmula del método de Newton representa una iteración del esquema que aproxima el cero de una representación lineal de la función. Esa aproximación lineal viene dada por:

$$\nabla f(\mathbf{x}_k + \mathbf{p}) \approx \nabla f(\mathbf{x}_k) + \nabla^2 f(\mathbf{x}_k)\mathbf{p}.$$

La aproximación lineal es el gradiente de la función cuadrática:

$$q_k(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2}\mathbf{p}^T \nabla^2 f(\mathbf{x}_k)\mathbf{p}.$$

Esto es, q_k corresponde a los tres primeros términos de la expansión en serie de Taylor de la función f alrededor del punto $\mathbf{x}_k$.

Ahora bien, la función cuadrática q_k ofrece una nueva interpretación del método de Newton para minimizar f. En cada una de las iteraciones del método, se aproxima f por q_k y luego, se minimiza q_k. Se actualiza entonces el valor $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{p}$. Esto es, en cada iteración se aproxima una función no lineal por una función cuadrática.

Salvo en casos degenerados, el método de Newton tiene convergencia cuadrática y esta convergencia no está garantizada. Si el método converge, entonces la convergencia se dará en un extremo relativo. Tal y como ha sido presentado aquí, no hay ninguna condición en el método que imponga que ese extremo realizará un mínimo. Estas cuestiones hacen que sea necesario adaptar el método para encontrar mínimos y para asegurar su convergencia (esto se puede hacer, claro está, siempre que la función tenga mínimos locales), lo cual será discutido más adelante.

Costes asociados al método de Newton

Hay tres tipos de costes asociados al uso del método de Newton:

1. El cálculo del esquema.
2. El cálculo de las derivadas.
3. El espacio de almacenamiento necesario para efectuar todas las operaciones.

Es de hacer notar que, en su versión clásica, un iterado del método de Newton requiere calcular las segundas derivadas y resolver un sistema lineal. Para una función de n variables, las dimensiones de la matriz Hessiana son $n \times n$. Además, se nota que

cada una de esas entradas significa, en general, programar cada una de las segunda derivadas parciales lo cual puede ser muy tedioso. En este sentido, hay que resolver un sistema lineal de dimensiones $n \times n$, lo cual tiene un coste computacional del orden de n^3. En resumen, el coste de un iterado del método de Newton crece rápidamente con n.

Hay varias maneras de abordar todos estos inconvenientes, por ejemplo en algunos problemas la matriz Hessiana tiene una forma particular (por ejemplo, muchas de sus entradas son nulas) y utilizando esa forma se puede adaptar tanto el almacenamiento de la matriz como el método para resolver el sistema lineal. Por otro lado, las derivadas se pueden calcular de forma automática utilizando calculo simbólico. Otra alternativa es modificar el método de Newton para reducir el costo computacional, teniendo en cuenta que ll método de Newton tiene convergencia cuadrática y esta convergencia no está garantizada. Si el método converge, entonces la convergencia se dará en un extremo relativo.

Estas modificaciones, en general, comprometerán la velocidad de convergencia del método. Esto es, la estrategia es aumentar el número de iterados del método pero reduciendo el coste computacional de cada uno de ellos. En las siguientes secciones se explorarán dos estrategias distintas para conseguir el compromiso deseado entre el número de iterados y su coste computacional: El **método del gradiente** y los **métodos Cuasi-Newton**.

El pseudocódigo para el método de Newton puede verse de la forma:

Algoritmo Método de Newton
Establece punto inicial x y tolerancia ε
`Mientras` $\|\nabla f(\boldsymbol{x})\| > \varepsilon$ `realiza` `Calcula` $\nabla f(\boldsymbol{x})$ `Calcula` $\nabla^2 f(\boldsymbol{x})$ y $[\nabla^2 f(\boldsymbol{x})]^{-1}$ `Actualiza` $\boldsymbol{x} \leftarrow \boldsymbol{x} - [\nabla^2 f(\boldsymbol{x})]^{-1} \nabla f(\boldsymbol{x})$
Imprime x y $f(\boldsymbol{x})$

Ejemplo 1. Método de Newton

Determine

$$\min_{(x_1,x_2)\in\mathbb{R}^2} f(x_1,x_2) = 3x_1^2 - 2x_1x_2 + x_2^2 + 3e^{-x_1}$$

Tomando $\mathbf{x}_0 = (0,0)$ y una tolerancia $\varepsilon = 0.001$.

Paso 1 Calculamos $\nabla f(x_1,x_2)$ y $\nabla^2 f(x_1,x_2)$

$$\nabla f(x_1,x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \rightarrow \nabla f(0,0) = \begin{bmatrix} -3 \\ 0 \end{bmatrix}$$

y

$$\nabla^2 f(x_1,x_2) = \begin{bmatrix} 6 + 3e^{-x_1} & -2 \\ -2 & 2 \end{bmatrix}$$

Paso 2 Calculamos $[\nabla^2 f(x_1,x_2)]^{-1}$ y evaluamos $\mathbf{x}_0 = (0,0)$:

$$[\nabla^2 f(x_1,x_2)]^{-1} = \frac{1}{8+6e^{-x_1}} \begin{bmatrix} 2 & 2 \\ 2 & 6+3e^{-x_1} \end{bmatrix}$$

de donde

$$\boxed{[\nabla^2 f(0,0)]^{-1} = \frac{1}{14} \begin{bmatrix} 2 & 2 \\ 2 & 9 \end{bmatrix}}$$

Paso 3 Buscamos el primer iterado:

$$\begin{aligned} \mathbf{x}_1 &= \mathbf{x}_0 - [\mathbf{H}_f(\mathbf{x}_0)]^{-1}\nabla f(\mathbf{x}_0) \\ &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \frac{1}{14}\begin{bmatrix} 2 & 2 \\ 2 & 9 \end{bmatrix}\begin{bmatrix} -3 \\ 0 \end{bmatrix} = \frac{1}{7}\begin{bmatrix} 3 \\ 3 \end{bmatrix} \end{aligned}$$

Paso 4 Calculamos $\|\nabla f(\mathbf{x}_1)\|$

$$\left\|\nabla f\left(\frac{3}{7},\frac{3}{7}\right)\right\| = \sqrt{\frac{18}{49}} \approx 0.60609 > 0.001$$

Paso 5 Buscamos el segundo iterado:

$$\nabla f\left(\frac{3}{7},\frac{3}{7}\right)=\begin{bmatrix}-0.2400\\ 0.0000\end{bmatrix} \text{ y } \left[\nabla^2 f\left(\frac{3}{7},\frac{3}{7}\right)\right]^{-1}=\begin{bmatrix}0.1679 & 0.1679\\ 0.1679 & 0.6679\end{bmatrix}$$

Luego,

$$\begin{aligned}\mathbf{x}_2 &= \mathbf{x}_1-[\mathbf{H}_f(\mathbf{x}_1)]^{-1}\nabla f(\mathbf{x}_1)\\ &= \frac{1}{7}\begin{bmatrix}3\\ 3\end{bmatrix}-\begin{bmatrix}0.1679 & 0.1679\\ 0.1679 & 0.6679\end{bmatrix}\begin{bmatrix}-0.2400\\ 0.0000\end{bmatrix}=\begin{bmatrix}0.4689\\ 0.4689\end{bmatrix}\end{aligned}$$

Calculamos $\|\nabla f(\mathbf{x}_2)\|$

$$\|\nabla f(\mathbf{x}_2)\|=\|(-0.00147,0)\|=0.00147>0.001$$

Paso 6 Buscamos el tercer iterado, entonces:

$$\nabla f\left(0.4689,0.4689\right)=\begin{bmatrix}-0.00147\\ 0.00000\end{bmatrix}$$

y

$$\left[\nabla^2 f\left(0.4689,0.4689\right)\right]^{-1}=\begin{bmatrix}0.17015 & 0.17015\\ 0.17015 & 0.67015\end{bmatrix}$$

$$\begin{aligned}\mathbf{x}_3 &= \mathbf{x}_2-[\mathbf{H}_f(\mathbf{x}_2)]^{-1}\nabla f(\mathbf{x}_2)\\ &= \begin{bmatrix}0.4689\\ 0.4689\end{bmatrix}+\begin{bmatrix}0.17015 & 0.17015\\ 0.17015 & 0.67015\end{bmatrix}\begin{bmatrix}0.00147\\ 0.00000\end{bmatrix}=\begin{bmatrix}0.4691\\ 0.4691\end{bmatrix}\end{aligned}$$

Paso 7 Calculamos $\|\nabla f(\mathbf{x}_3)\|$

$$\|\nabla f(\mathbf{x}_3)\|=\|(-0.000295,0)\|=0.000295<0.001$$

Por tanto, detenemos el algoritmo y se imprime el valor de $\mathbf{x}_3=(0.4691,0.4691)$ y su valor en la función:

$$f(0.4691,0.4691)=2.31680$$

Método de Newton				
k	x_1	x_2	$\|\nabla f(x_1, x_2)\|$	$f(x_1, x_2)$
0	0	0	3	3
1	0.42857	0.42857	0.60609	2.321660
2	0.46890	0.46890	0.00147	2.316804867
3	0.46910	0.46910	0.0002951	2.316804691

Ejemplo 2. Newton

Aplicar el método de Newton al siguiente problema de minimización sin restricciones:

$$\text{minimizar } (x-2)^4 + (x-2)^2y^2 + (y+1)^2$$

Nota: Resulta sencillo verificar que en efecto, la solución a este problema es justamente: $\boldsymbol{x}^* = (2, -1)$.

Paso 1 **Calcular el Gradiente de f y la Matriz Hessiana**

- $\nabla f(x, y) = (4(x-2)^3 + 2(x-2)y^2, 2(x-2)^2y + 2(y+1))$
- $Hf(x, y) = \begin{bmatrix} 12(x-2)^2 + 2y^2 & 4(x-2) \\ 4(x-2)y & 2(x-2)^2 + 2 \end{bmatrix}$

Paso 2 **Evaluar en el punto inicial**

- $\nabla f(1, 1) = (-6, 6)$
- $Hf(1, 1) = \begin{bmatrix} 14 & -4 \\ -4 & 4 \end{bmatrix}$

Paso 3 **Hallar la inversa a la matriz Hessiana**

$$[Hf(1,1)]^{-1} = \begin{bmatrix} 14 & -4 \\ -4 & 4 \end{bmatrix}^{-1} \rightarrow [Hf(1,1)]^{-1} = \frac{1}{20}\begin{bmatrix} 2 & 2 \\ 2 & 7 \end{bmatrix}$$

Paso 4 **Calcular el primer iterado x_1**

$$\begin{aligned} \mathbf{x}_1 &= \mathbf{x}_0 - [Hf(\mathbf{x}_0)]^{-1}\nabla f(\mathbf{x}_0) \\ &= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{20}\begin{bmatrix} 2 & 2 \\ 2 & 7 \end{bmatrix}\begin{bmatrix} -6 \\ 6 \end{bmatrix} = \begin{bmatrix} 1 \\ -0.5 \end{bmatrix} \end{aligned}$$

Método de Newton

Iteración	x	y	$\|\nabla f(x,y)\|$
0	1.000000	1.000000	8.485281e+00
1	1.000000	-0.500000	4.500000e+00
2	1.391304	-0.695652	1.494157e+00
3	1.745944	-0.948798	5.233879e-01
4	1.986278	-1.048208	1.014011e-01
5	1.998734	-1.000170	2.555613e-03
6	2.000000	-1.000002	3.319064e-06
7	2.000000	-1.000000	2.808149e-12

Tabla 1: Iterados del método de Newton. La primera columna muestra los iterados. La segunda y tercera columna muestran las coordenadas de la aproximación del óptimo. La cuarta columna muestra la condición de optimalidad.

Podemos comprobar los resultados en Matlab ➔

Método de Newton - Dos Variables

```
%% ALGORITMO DE NEWTON - DOS VARIABLES
%% f(X1,X2)=(X1-2)^4+(X1-2)^2*X2^2+(X2+1)^2
%% Calculo del Gradiente de f
Df= @(x) [(4*(x(1)-2)^3 + 2*(x(1)-2)*x(2)^2);
              (2*x(2)*(x(1)-2)^2+2*(x(2)+1))];
%% Cálculo de la Matriz Hessiana
DDf = @(x) [(12*(x(1)-2)^2+2*x(2)^2)  ...
   (4*(x(1)-2)*x(2));
             (4*(x(1)-2)*x(2))  (2*(x(1)-2)^2+2)];
%% Parámetros de Inicio del Algoritmo
```

```
x0 =[1,1];    % Iterado Inicial - Punto de Inicio
maxiter=10;   % Número máximo de iteraciones
tol =1E-12;   % Tolerancia pedida - Criterio de Parada
x=x0;         % Inicio de las Variables
iter =0;      % Contador de iteraciones
%% Ciclo para generar los iterados
while iter<maxiter
D=Df(x);                  % Vector Gradiente
n1= sqrt(D'*D);           % Norma del Vector ...
   Gradiente - Criterio de Parada
% Se imprime cada iterado y el error que se comete ...
   en la iteración
sprintf (" Iterado %d, aprox=( %f, %f), error= %e ...
   \n", iter , x, n1)
h= DDf(x)\D;              % Cálculo del p ...
   correspondiente
n2= sqrt(h'*h);           % Norma de p - Segundo ...
   Criterio de Parada
x=x-h';                   % Actualización del punto ...
   x=(x(1),x(2))
if (n1<tol) || (n2<tol) % Pregunta para Criterio ...
   de Parada
iter = maxiter ;
break;
end
iter = iter +1;           % Actualización del Contador
end
```

En la siguiente sección, se estudiará un método que es, posiblemente, la forma más sencilla de modificar el método de Newton para aplicarlo a la optimización no lineal.

4.4 El método del gradiente

El **método del gradiente** si bien es cierto una forma sencilla de modificar el método de Newton, el precio a pagar por esa sencillez es una gran ineficiencia en términos de velocidad de convergencia para la mayoría de problemas. Esto es: Aunque es muy barato calcularlos, necesita muchos iterados para converger. Veremos que un iterado de este método no requiere ni calcular la segunda derivada de la función ni resolver un sistema lineal. Consecuentemente no hace falta reservar espacio para almacenar una matriz.

Definición 1: Dirección de Descenso

Sean $f : \mathcal{F} \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}$. Se dice que $\mathbf{d} \in \mathbb{R}^n$ es una **dirección de descenso** para f en $\mathbf{x}_0$ si existe $t_0 \in \mathbb{R}^+$, tal que $f(\mathbf{x}_0) > f(\mathbf{x}_0 + t\mathbf{d})$, para todo $t \in (0, t_0)$. □

Partiendo del punto $\mathbf{x}_0$, el vector $\mathbf{d}$ apunta en una dirección de descenso de f, si existe un conjunto de vectores de desplazamiento $t\mathbf{d}$, lo suficientemente pequeños, para los que el valor de f decrece al evaluarse en los puntos de llegada $\mathbf{x}_0 + t\mathbf{x}$.

Siendo t suficientemente pequeño y utilizando el teorema de Taylor, con $\mathbf{d}$ una *dirección de descenso*, se cumple que:

$$f(\mathbf{x}_0) > f(\mathbf{x}_0 + t\mathbf{d}) \approx f(\mathbf{x}_0) + t\nabla f(\mathbf{x}_0)^T\mathbf{d}$$

Proposición 1

Sea $f \in \mathcal{C}^1(\mathcal{F})$, con $\mathcal{F} \subseteq \mathbb{R}^n$ y $\mathbf{d}$ es una dirección de descenso de f en $\mathbf{x}_0$, si y sólo si, $\nabla f(\mathbf{x}_0)^T\mathbf{d} < 0$. □

Observación: Notando el producto interno, $\nabla f(\mathbf{x}_0)^T \cdot \mathbf{d}$ se tiene que:

$$\nabla f(\mathbf{x}_0)^T \cdot \mathbf{d} = \|\nabla f(\mathbf{x}_0)\|\|\mathbf{d}\| \cos\theta$$

entonces, la dirección de máximo crecimiento es la del gradiente y la de menor crecimiento negativo, es la opuesta a él.

Ejemplo 3. Gradiente

En la figura, se muestran algunas curvas de nivel de la función $f(x_1, x_2) = x_1^2 + 4x_2^2$. Es una función convexa en todo $\mathbb{R}^2$ y tiene su mínimo en $(0, 0)$. Determinar la dirección de descenso más pronunciado en el punto $(1, 0.5)$.

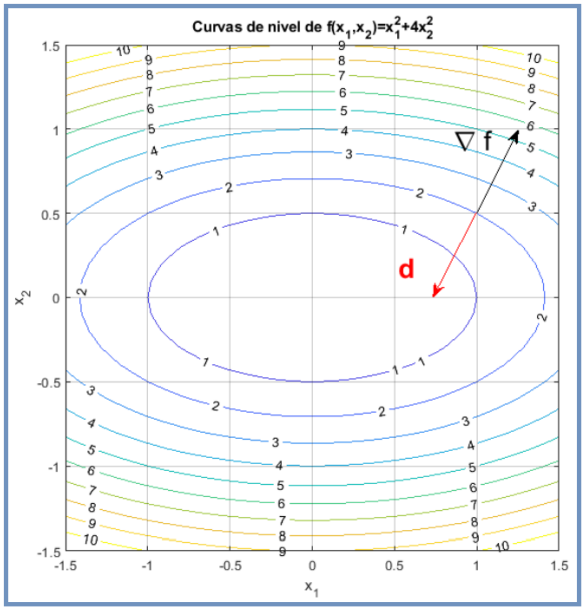

Paso 1 Determinar el Gradiente:

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 8x_2 \end{bmatrix} \rightarrow \nabla f(1, 0.5) = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

Paso 2 Entonces, la dirección de máximo descenso está dada por:

$$\mathbf{d} = -\nabla f(1, 0.5) = \begin{bmatrix} -2 \\ -4 \end{bmatrix}$$

o en su defecto cualquier múltiplo positivo de este.

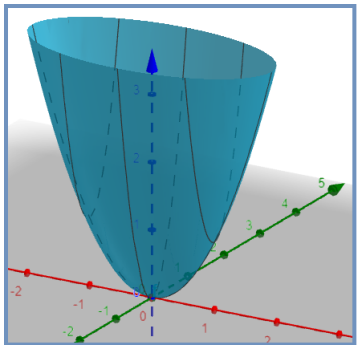

Lema 1: Dirección de Máximo Descenso

Sea $f \in \mathcal{C}^1(\mathcal{F})$, con $\mathcal{F} \subseteq \mathbb{R}^n$. La dirección de máximo descenso de f en $\mathbf{x} \in \mathcal{F}$, es justamente: $\mathbf{d}_{\text{máx}} = -\nabla f(\mathbf{x})$. $\square$

Organizando ideas

- Encontrar un punto $\mathbf{x}$ donde la función f tenga un mínimo local.
- Hallar un mecanismo que permita ir de un punto dado a otro haciendo que el valor de la función decrezca en el camino.
- Sabemos que en un entorno o vecindad suficientemente pequeño de $\mathbf{x}^*$ el negativo del gradiente apuntaría en la dirección de máximo descenso.
- Si $\mathbf{d}_{\text{máx}}$ es la dirección de descenso máximo en $\mathbf{x}$, se quisiera determinar $t^* > 0$ talque $f(\mathbf{x} + t^*\mathbf{d}_{\text{máx}})$ sea mínima.
- Se debe observar que esto constituye en sí mismo un problema de optimización en una variable, para resolverlo se puede echar mano de mucha herramienta vista antes.
- Estamos entonces, ante un proceso de construcción de una sucesión de puntos $\{\mathbf{x}_k\}$. **¿Cuándo nos detenemos?**
- **Criterios de Parada:** Podemos pensar en:

(a) $\|\mathbf{x}_{k+1} - \mathbf{x}_k\| < \varepsilon$, para $\varepsilon > 0$ y suficientemente pequeño.

(b) Si existe un mínimo en $\mathbf{x}^*$, entonces $\nabla f(\mathbf{x}) \to 0$ cuando $\mathbf{x} \to \mathbf{x}^*$, entonces el proceso se detiene cuando $\|\nabla f(\mathbf{x})\| < \varepsilon$.

Esquema

El método del gradiente tiene el siguiente esquema:

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k - t^* \nabla f(\mathbf{x}_k)}$$

donde $t^* > 0$, es un escalar tal que $f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$. Entonces, la dirección $\mathbf{d}_k = -\nabla f(\mathbf{x}_k)$ es una dirección de descenso (cerca de un mínimo) a no ser que $\nabla f(\mathbf{x}_k) = \mathbf{0}$.

Si el escalar t^* es suficientemente pequeño, entonces: $f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$. Esto equivale a requerir que t^* sea solución del problema de optimización 1-dimensional:

$$\boxed{\text{minimizar } F(t) = f(\mathbf{x}_k + t\mathbf{d}_k)}$$

El pseudocódigo para el método del Gradiente puede verse de la forma:

El pseudocódigo para el método de Newton puede verse de la forma:

Algoritmo Método del Gradiente - Descenso Máximo
Establece punto inicial x y tolerancia ε
`Mientras` $\|\nabla f(\mathbf{x})\| > \varepsilon$ `realiza` `Resuelve` $\min_{t>0} f(\mathbf{x} - t\nabla f(\mathbf{x}))$ `-->` t^* `Actualiza` $\mathbf{x} \leftarrow \mathbf{x} - t^* \nabla f(\mathbf{x})$
Imprime x y $f(x)$

Este esquema se obtiene del método de Newton haciendo una aproximación grande de la matriz Hessiana. En particular, se asume que: $\nabla^2 f \approx I$, donde I representa la matriz identidad. Esta aproximación tan burda de la segunda derivada hace que la velocidad de convergencia del método del gradiente sea lineal.

En general se tiene que:

$$f(\mathbf{x}_{k+1}) - f(\mathbf{x}^*) \leq \left[\frac{\text{cond}(Q) - 1}{\text{cond}(Q) + 1}\right]^2 (f(\mathbf{x}_k) - f(\mathbf{x}^*))$$

donde $\text{cond}(Q) = \|Q\|\|Q^{-1}\|$, es el número de condición de la matriz: $Q := \nabla^2 f(\mathbf{x}^*)$. Para funciones cuyo Hessiano tenga $\text{cond}(Q) \approx 1$ la convergencia será aceptable y podremos utilizarla.

Ejemplo 4. Gradiente

Considera la función $f(x, y) = y \operatorname{sen} x - y^2 + 2y^3$. Determina un mínimo de la función en el intervalo $[-\pi, \pi] \times [-1, 1]$ usando el método del gradiente considerando como $\mathbf{x}_0 = (-1, 0.125)$.

Paso 1 Calcular el gradiente de f:

$$\nabla f(x, y) = (y \cos x, \operatorname{sen} x - 2y + 6y^2)$$

Paso 2 Inicio del esquema en $\mathbf{x}_0 = (-1, 0.125)$. Entonces,

$$\begin{aligned} \nabla f(\mathbf{x}_0) &= \nabla f(-1, 0.125) \\ &= (0.125 \cos(-1), \operatorname{sen}(-1) - 2(0.125) + 6(0.125)^2) \\ &= (0.068, -0.998) \end{aligned}$$

Paso 3 Ahora, podemos emplear un paso t constante para acercarnos al óptimo, por ejemplo $t = 0.3$. Así pues,

$$\mathbf{x}_1 = \mathbf{x}_0 - 0.3\nabla f(-1, 0.125) = (-1.02, 0.42)$$

Paso 4 Como $\|\mathbf{x}_1 - \mathbf{x}_0\| = 0.13$, consideramos que todavía no estamos en el mínimo y seguimos calculando.

Paso 5 Repetimos este procedimiento una segunda vez de forma que:

$$\nabla f(\mathbf{x}_1) = \nabla f(-1.02, 0.42) = (0.22, -0.63)$$

Paso 6 El nuevo valor vendrá dado por:

$$\mathbf{x}_2 = \mathbf{x}_1 - 0.3\nabla f(\mathbf{x}_1) = (-1.09, 0.61)$$

Nota: El método lo podemos depurar realizando la búsqueda lineal de forma que el valor de t que seleccionamos no esté prefijado sino que tomemos el valor óptimo de t.

¿Cómo hallamos el t^* óptimo?

Para ello, se pueden emplear métodos de búsqueda, tales como: búsqueda dicotómica, razón áurea, Fibonacci, etc.

En ese caso, tendremos que encontrar el valor de $t > 0$ tal que $f(\mathbf{x}_0 - t\nabla f(\mathbf{x}_0))$ es mínimo. Para el primer iterado obtenemos que el valor de t óptimo será $t^* = 0.378$, de forma que el nuevo valor será $\mathbf{x}_1 = (-1.10, 0.63)$.

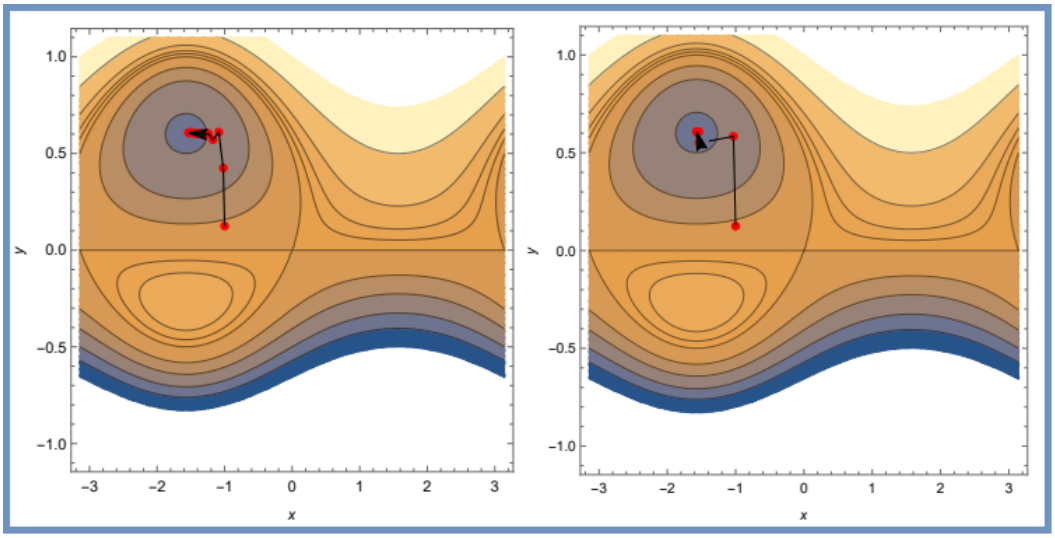

Figura 1: Curvas de nivel de la función f del **Ejemplo 4**. En rojo los puntos recorridos con la primera (izquierda) y segunda (derecha) versiones del método del gradiente.

Nota: Para calcular el máximo debemos cambiar el signo de la actualización de $\mathbf{x}_{n+1} = \mathbf{x}_n - t^*\nabla f(\mathbf{x}_n)$ a $\mathbf{x}_{n+1} = \mathbf{x}_n + t^*\nabla f(\mathbf{x}_n)$

Ejemplo 5. Gradiente

Determine

$$\min_{(x_1,x_2)\in\mathbb{R}^2} f(x_1,x_2) = 3x_1^2 - 2x_1x_2 + x_2^2 + 3e^{-x_1}$$

Tomando $\mathbf{x}_0 = (0,0)$ y una tolerancia $\varepsilon = 0.001$.

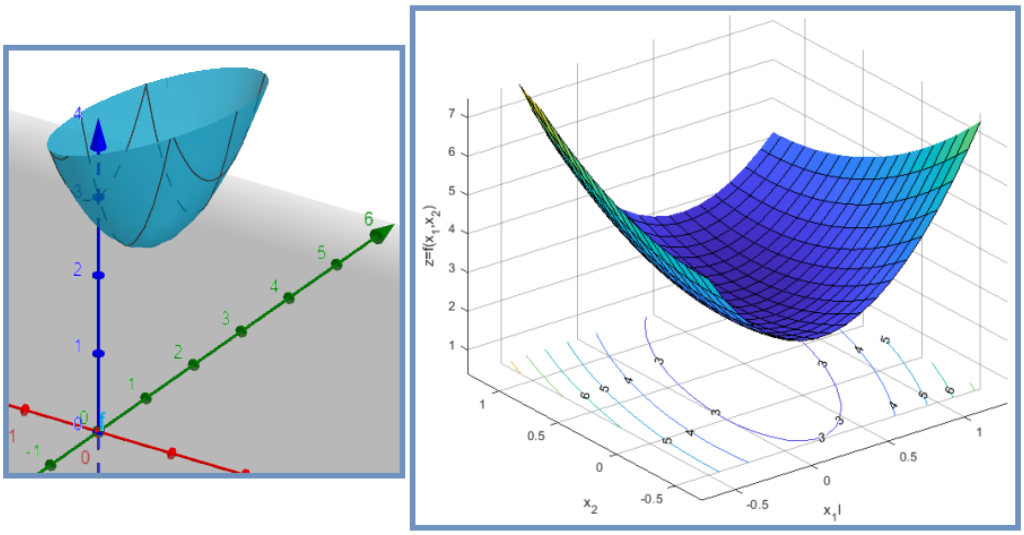

Figura 2: Grafica de la función f desde distintas perspectivas.

Paso 1 Calculamos $\nabla f(x_1,x_2)$

$$\nabla f(x_1,x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \rightarrow \nabla f(0,0) = \begin{bmatrix} -3 \\ 0 \end{bmatrix}$$

Paso 2 Buscamos la dirección de máximo descenso:

$$\mathbf{d}_0 = -\nabla f(\mathbf{x}_0) \rightarrow \mathbf{x}_0 + t\mathbf{d}_0 = (0,0) + t(3,0) = (3t,0)$$

Paso 3 Buscamos el t óptimo:

$$F(t) = f(\mathbf{x}_0 + t\mathbf{d}_0) = 3(3t)^2 + 3e^{-3t} = 27t^2 + 3e^{-3t}$$

Luego, $F'(t) = 54t - 9e^{-3t} = 0$.

Paso 4 Usando algún método de búsqueda se puede ver que el óptimo está cerca de $\boxed{t^* \approx 0.12}$. Entonces,

$$\mathbf{x}_1 = \mathbf{x}_0 - 0.12\nabla f(\mathbf{x}_0) = (0.36, 0) \quad \rightarrow \quad f(0.36, 0) \approx 2.5$$

Paso 5 Repetimos el proceso para $\mathbf{x}_2$. Entonces,

$$\nabla f(x_1, x_2) = \begin{bmatrix} 6x_1 - 2x_2 - 3e^{-x_1} \\ -2x_1 + 2x_2 \end{bmatrix} \quad \rightarrow \quad \nabla f(0.36, 0) \approx \begin{bmatrix} 0.06697 \\ -0.72000 \end{bmatrix}$$

Luego, $\mathbf{d}_1 = -\nabla f(\mathbf{x}_1) = (-0.06697, 0.72000)$

$$\begin{aligned} \mathbf{x}_1 + t\mathbf{d}_1 &= (0.36, 0) + t(-0.06697, 0.72000) \\ &= (0.36 - 0.06697\,t, 0.72000\,t) \end{aligned}$$

de donde

$$\begin{aligned} F(t) &= f(0.36 - 0.06697\,t, 0.72000\,t) \\ &= 0.3888 - 0.53286\,t + 0.61495\,t^2 + 2.09302e^{0.06697\,t} \end{aligned}$$

lo cual implica que:

$$F'(t) = -0.53286 + 1.2299\,t + 0.14016e^{0.06697\,t} = 0 \quad \rightarrow \quad \boxed{t \approx 0.317}$$

En este sentido,

$$\mathbf{x}_2 = (0.36, 0) + 0.317(-0.06697, 0.72) = (0.33877, 0.22824)$$

en consecuencia,

$$f(\mathbf{x}_2) = f(0.33877, 0.22824) \approx 2.38$$

...Y así sucesivamente... ■

Ejemplo 6. Gradiente

Considera la función $f(x, y) = x^2 - 24x + y^2 - 10y$. Determina el mínimo.

Paso 1 Sea $\mathbf{x}_0 = (8, 7)$ un punto de partida cualquiera y aplicamos una iteración del método.

Paso 2 Calcular el gradiente de f:

$$\nabla f(x, y) = (2x - 24, 2y - 10) \quad \rightarrow \quad \nabla f(8, 7) = (-8, 4)$$

Paso 3 Calculamos la magnitud del paso t:

$$\begin{aligned} F(t) &= f(\mathbf{x}_0 - t\nabla f(\mathbf{x}_0)) = f((8, 7) - t(-8, 4)) \\ &= (8 + 8t)^2 - 24(8 + 8t) + (7 - 4t)^2 - 10(7 - 4t) \end{aligned}$$

saffamilyPaso 4 Busquemos el valor extremo de t^*:

$$\begin{aligned} F'(t) &= 16(8 + 8t) - 192 - 8(7 - 4t) + 40 \\ &= 160t - 80 \rightarrow g'(t) = 0 \leftrightarrow \boxed{t^* = \tfrac{1}{2}} \end{aligned}$$

Paso 5 Ahora, podemos emplear un paso t^* constante para acercarnos al óptimo. Así pues,

$$\mathbf{x}_1 = \mathbf{x}_0 - t^*\nabla f(\mathbf{x}_0) = (8, 7) - \frac{1}{2}(-8, 4) = (12, 5)$$

Nota: El punto de partida para comenzar las iteraciones es arbitrario y al ser evaluado en la función objetivo se alcanza un valor de $f(8, 7) = -149$.

Ahora bien, si evaluamos la coordenada que se alcanza al realizar una iteración del método la función objetivo obtiene el siguiente valor $f(12, 5) = -169$ que como se puede apreciar reduce el valor de la función objetivo.
m

¿Cómo determinar si se ha alcanzado la solución óptima del problema no restringido a través del Método del Gradiente?

Para ello se debe verificar que la dirección de descenso en la k-ésima iteración es nula. En efecto, $\nabla f(12,5) = (0,0)$.

En efecto, se puede realizar una comprbación final, mediante elñ cálculo de la Matriz Hessiana:

$$Hf(x,y) = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Observe que: $M_1 = 2 > 0$ y $M_2 = 4 > 0$, por tanto, la matriz es definida positiva.

La función objetivo es estrictamente convexa y esto garantiza que $x_1 = (12,5)$ realiza el mínimo y es la solución óptima esperada.

Método del Gradiente

```
%% PARAMETROS Y DATOS PARA SER AGREGADOS POR EL ...
   USUSARIO
Max=0;
f=@(x,y) x^2-24*x + y^2-10*y;   % Función
grad={@(x,y) 2*x-24, ...
      @(x,y) 2*y-10};% Gradiente
x0=[8;7];% Punto inicial
Tol=0.09;% Tolerancia
MaxIter=100;% Iteraciones
bk=5;% Límite superior
t=0.5;% parámetro del algoritmo
%% INICIO DEL ALGORITMO
Fgrad=[grad{1}(x0(1,1),x0(2,1))
       grad{2}(x0(1,1),x0(2,1))];
if Max==1
    Fgrad=Fgrad;% Si se maximiza--> gradiente
else
    Fgrad=-Fgrad;   % Si se minimiza--> se - gradiente
```

```
end
iter=1; % Inicio de las iteraciones
while norm(Fgrad)>=Tol && iter<=MaxIter
    D(iter, :)={iter,x0,Fgrad,t}
    x0=x0+t*Fgrad; % Actualizacion
      Fgrad=[grad{1}(x0(1,1),x0(2,1))
       grad{2}(x0(1,1),x0(2,1))];
      if Max==1
          Fgrad=Fgrad;% Si se maximiza se escoge ...
             el gradiente
      else
          Fgrad=-Fgrad; % Si se minimiza
      end
      iter=iter+1;       % Se actualiza el contador
     D(iter,:)={iter, x0, Fgrad, t}
end
```

4.5 Métodos Cuasi-Newton

Los métodos **Cuasi-Newton** se encuentran en el grupo de métodos de optimización no-lineal más utilizados. Son buenos para encarar un amplio abanico de problemas de tamaño medio y pequeño. Particularmente cuando la matriz Hessiana es difícil (o costosa) de calcular.

Cuando el número de variables es alto, otros métodos son más adecuados. Eso sí, representan una base para algoritmos más complicados que sí son indicados para problemas de dimensión alta.

La idea de un método cuasi-Newton es reemplazar el cálculo de la matriz Hessiana por otra matriz B_k que sea menos exigente de calcular, en términos computacionales. Hay

tantos métodos cuasi-Newton como maneras de aproximar la matriz Hessiana. Una vez se ha elegido la manera para aproximar la matriz Hessiana, el resto del método sigue como el método de Newton clásico. Es decir, el gran cambio es que el sistema lineal que se resuelve es

$$B_k \mathbf{p} = -\nabla f(\mathbf{x}_k)$$

Si la matriz B_k es definida positiva, esto equivale a minimizar un modelo cuadrático, esto es, abordamos el siguiente problema:

$$\text{minimizar} \quad q(\mathbf{p}) = f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \mathbf{p} + \frac{1}{2}\mathbf{p}^T B_k \mathbf{p}$$

El paso crítico para obtener un buen método cuasi-Newton es escoger una buena aproximación de la matriz Hessiana. Esto tiene una ventaja inicial evidente: Se puede aproximar la segunda derivada utilizando sólo evaluaciones de la primera derivada. Además, se puede encontrar la dirección en que actualizar la aproximación del óptimo con un número de operaciones del orden del cuadrado de la dimensión (recordemos que en el caso del método de Newton el orden era el cubo de ésta). Otra vez, el precio que se paga con esta estrategia es no obtener una convergencia cuadrática. Eso sí, a diferencia del método del gradiente, esta convergencia puede ser superlineal. El problema que no resuelven este tipo de métodos es el del almacenamiento de la aproximación matriz Hessiana.

Es posible que el lector, a estas alturas, ya haya relacionado los métodos cuasi-Newton con un método clásico para encontrar ceros de funciones: El método de la secante para funciones uno-dimensionales. En efecto, la idea principal del método de la secante es aproximar la derivada mediante cocientes incrementales (una aproximación de primer orden de la derivada). El método de la secante adaptado a la optimización de funciones uno-dimensionales se escribe de la siguiente forma:

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})} f'(x_k),$$

en donde se usa la aproximación:

$$f''(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}.$$

Esta fórmula no se tiene sentido en el caso multidimensional ya que requeriría dividir por un vector. La aproximación que sí tiene sentido es la siguiente:

$$\nabla^2 f(\boldsymbol{x}_k)(\boldsymbol{x}_k - \boldsymbol{x}_{k-1}) \approx \nabla f(\boldsymbol{x}_k) - \nabla f(\boldsymbol{x}_{k-1}).$$

Esto es, una posible manera de aproximar B_k es mediante su acción sobre el vector $\boldsymbol{x}_k - \boldsymbol{x}_{k-1}$:

$$B_k(\boldsymbol{x}_k - \boldsymbol{x}_{k-1}) = \nabla f(\boldsymbol{x}_k) - \nabla f(\boldsymbol{x}_{k-1}).$$

A esta fórmula se la llama *condición de la secante*. Para una función f multidimensional; digamos, de dimensión n; esta condición se traduce en un sistema lineal de n ecuaciones. Las variables de este sistema son las entradas de B_k, esto es, hay n^2 variables, resultando el sistema indeterminado. Esto significa que se habrán de imponer condiciones extras para tener una única solución.

La condición de la secante es especialmente relevante cuando la función objetivo es una función cuadrática

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T Q \boldsymbol{x} - c^T \boldsymbol{x}.$$

En este caso,

$$Q(\boldsymbol{x}_k - \boldsymbol{x}_{k-1}) = (Q\boldsymbol{x}_k - x) - (Q\boldsymbol{x}_{k-1} - c) = \nabla f(\boldsymbol{x}_k) - \nabla f(\boldsymbol{x}_{k-1}).$$

Esto es, la matriz Q (la matriz Hessiana de f) satisface directamente la condición de la secante. Otra manera de decir esto es que la aproximación que estamos buscando actúa en la dirección $\boldsymbol{x}_k - \boldsymbol{x}_{k-1}$ de la misma forma que lo hace la matriz Hessiana. Este punto de vista es solamente válido para funciones cuadráticas. Para funciones de orden superior podemos interpretar la condición de la secante como imponer que B_k aproxime el efecto de la Hessiana en la dirección $\boldsymbol{x}_k - \boldsymbol{x}_{k-1}$.

Para facilitar un poco la notación, renombraremos algunas cantidades. Definimos $\mathbf{s}_k := \mathbf{x}_{k+1} - \mathbf{x}_k$ y $\mathbf{y}_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k)$. La condición de la secante se escribirá, de forma más conveniente, como

$$B_{k+1}\mathbf{s} = \mathbf{y}_k.$$

Notamos, de la definición de $\mathbf{s}_k$ que podemos escribir el esquema iterativo

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{s}_k.$$

El único problema que tenemos que solventar es encontrar la aproximación B_k para cada k. Ya hemos comentado que B_k debe de satisfacer la condición de la secante. También hemos comentado que eso no es suficiente para determinarla unívocamente. La estrategia común es añadir alguna condición que cumpla la matriz Hessiana. En condiciones de regularidad suficiente, la matriz Hessiana es simétrica: Parece una buena opción requerirlo también en la matriz B_k, para todo k. Si vemos B_{k+1} como una corrección de B_k, esto es

$$B_{k+1} = B_k + C.$$

Con un poco de trabajo, puede demostrarse que si B_k y B_k son matrices simétricas que cumplen la condición de la secante, y $(\mathbf{y}_k - B_k\mathbf{s}_k)^T\mathbf{s}_k \neq 0$, entonces

$$C = \frac{(\mathbf{y}_k - B_k\mathbf{s}_k)(\mathbf{y}_k - B_k\mathbf{s}_k)^T}{(\mathbf{y}_k - B_k\mathbf{s}_k)^T\mathbf{s}_k}. \tag{1}$$

Con todos estos elementos, podemos escribir el algoritmo de un método cuasi-Newton:

1. Escogemos dos condiciones iniciales para el método iterativo. Una aproximación de la solución x_0 y una aproximación de la matriz Hessiana B_0 (a falta de una mejor aproximación se suele escoger $B_0 = I$. Seleccionamos también una tolerancia $\varepsilon > 0$.

2. Para $k \geq 0$

   a) Se comprueba la condición de optimalidad $\|\nabla f(\mathbf{x}_k)\| < \varepsilon$. En caso de satisfa-

cerla, se retorna el valor $\mathbf{x}_k$.

b) Se resuelve el sistema $B_k\mathbf{p}_k = -\nabla f(\mathbf{x}_k)$ para $\mathbf{p}_k$.

c) Se actualiza la aproximación del óptimo: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k$, para un cierto paso $\alpha_k > 0$.

d) Se calculan las cantidades

$$\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k,$$

$$\mathbf{y}_k = \nabla f(\mathbf{x}_{k+1}) - \nabla f(\mathbf{x}_k).$$

e) Se actualiza la aproximación de la matriz Hessiana: $B_{k+1} = B_k + C$. Aquí, C viene dada por la fórmula (1).

Ejemplo 7.

Consideramos el problema de minimización en $\mathbb{R}^3$ dada por la función cuadrática $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q\mathbf{x} - c^T\mathbf{x}$, donde

$$Q = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{bmatrix}, \quad c = \begin{bmatrix} -8 \\ -9 \\ -8 \end{bmatrix}.$$

Escrita en coordenadas (x_1, x_2, x_3), la función a minimizar es:

$$f(x_1, x_2, x_3) = x_2^2 + \frac{3}{2}x_2^2 + 2x_3^2 + 8x_1 + 9x_2 + 8x_3.$$

De manera que el gradiente viene dado por

$$\nabla f(x_1, x_2, x_3) = (2x_1 + 8, 3x_2 + 9, 4x_3 + 8).$$

La solución del problema de optimización es trivial de encontrar:

$$\mathbf{x}^* = (-4, -3, -2)^T.$$

Vamos a calcular un par de iterados del método cuasi-Newton que hemos explicado. En primer lugar, necesitamos sendas primeras aproximaciones de la solución y de la matriz Hessiana. A falta de una mejor idea, escogemos $\mathbf{x}_0 = 0$ y $B_0 = I$.

- Evaluamos la optimalidad de $\mathbf{x}_0$, $\|\nabla f(\mathbf{x}_0)\| = \|-c\| = 14.4568$. No hemos especificado una tolerancia pero, para cualquier valor razonable, no se cumple la condición de optimalidad.

- Resolvemos el sistema $B_0\mathbf{p}_0 = -\nabla f(\mathbf{x}_0)$. En este caso, el sistema es trivial de resolver ($B_0 = I$) y obtenemos $\mathbf{p}_0 = c$.

- En vistas de actualizar $\mathbf{x}_0$, tenemos que encontrar un paso α_0. Recordemos que, para hacer tal cosa, hay que optimizar la función $f(\mathbf{x}_0 + \alpha\mathbf{p}_0)$ en α. Como $\mathbf{x}_0 = 0$, de hecho solo hay que encontrar el mínimo de $f(\alpha p_0) = f(\alpha c) = 313.5\alpha^2 - 209\alpha$. Este mínimo se obtiene derivando con respecto α e igualando a 0. Se obtiene $\alpha_0 = 0.3333$. La nueva aproximación es

$$\mathbf{x}_1 = \begin{bmatrix} -2.6667 \\ -3.0000 \\ -2.6667 \end{bmatrix},$$

con

$$\nabla f(\mathbf{x}_1) = \begin{bmatrix} 2.6667 \\ 0.0000 \\ -2.6667 \end{bmatrix},$$

- Calculamos ahora las cantidades $\mathbf{s}_0$ y $\mathbf{y}_0$. Tenemos

$$\mathbf{s}_0 = \begin{bmatrix} -2.6667 \\ -3.0000 \\ -2.6667 \end{bmatrix}, \quad \mathbf{y}_0 = \begin{bmatrix} -5.3333 \\ -9.0000 \\ -10.6667 \end{bmatrix}.$$

Construimos la corrección de B_0 mediante la fórmula (1). Se obtiene

$$B_1 = \begin{bmatrix} 1.1531 & 0.3445 & 0.4593 \\ 0.3445 & 1.7751 & 1.0335 \\ 0.4593 & 1.0335 & 2.3780 \end{bmatrix}.$$

- La condición de optimalidad en este nuevo punto es $\|\nabla f(\mathbf{x}_1)\| = 3.7712$. Vemos que hemos mejorado la condición de optimalidad en un dígito. Para una

solución satisfactoria, debemos seguir iterando. Las cantidades para la siguiente iteración son:

- $\mathbf{p}_1 = (-2.9137, -0.5557, 1.9257)^{\mathsf{T}}$,
- $\alpha_1 = 0.3942$,
- $\mathbf{x}_2 = (-3.8152, -3.2191, -1.9076)^{\mathsf{T}}$,
- $\nabla f(\mathbf{x}_2) = (0.3697, -0.6572, 0.3697)^{\mathsf{T}}$,
- $\mathbf{s}_1 = (-1.1485, -0.2191, 0.7591)^{\mathsf{T}}$,
- $\mathbf{y}_1 = (-2.2970, -0.6572, 3.0363)^{\mathsf{T}}$,
- La actualización de la aproximación de la Hessiana es

$$B_2 = \begin{bmatrix} 1.6568 & 0.6102 & -0.3432 \\ 0.6102 & 1.9153 & 0.6102 \\ -0.3432 & 0.6102 & 3.6568 \end{bmatrix}.$$

Para este segundo iterado, la condición de optimalidad es $\|\nabla f(\mathbf{x}_2)\| = 0.8397$.