Optimización

Optimización con restricciones: Métodos de resolución.

Índice

Esquema 2

Ideas clave 3

6.1 Introducción 3

6.2 Objetivos 4

6.3 Métodos de Penalización 4

6.4 Gradiente reducido 7

6.5 Programación cuadrática secuencial 12

Esquema

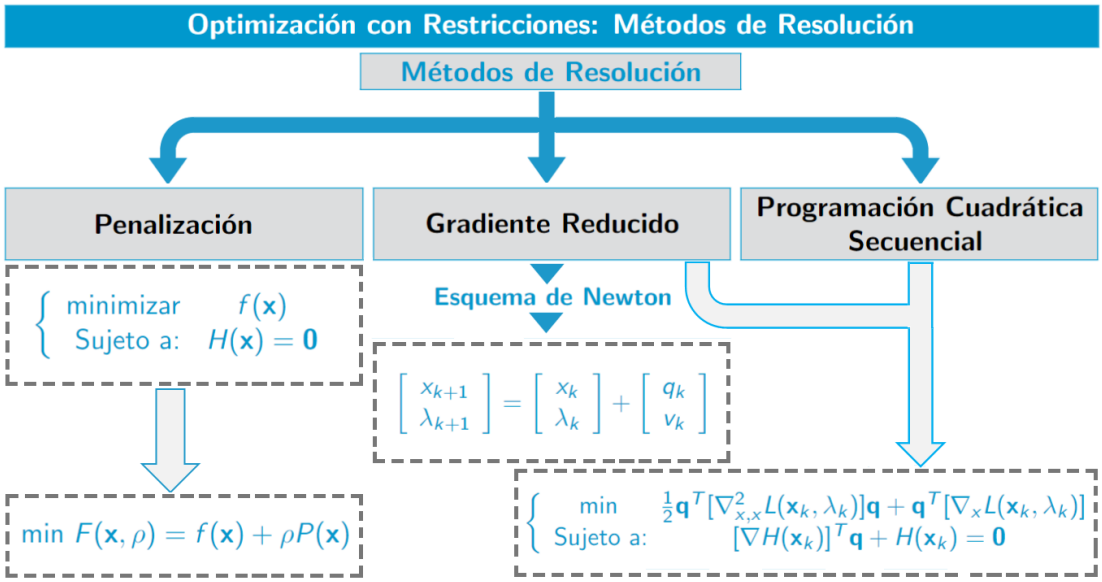
Optimización con Restricciones: Métodos de Resolución
Métodos de Resolución
Penalización
Gradiente Reducido
Programación Cuadrática Secuencial
$\begin{cases} \text{minimizar} & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$
Esquema de Newton
$\begin{bmatrix} x_{k+1} \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ \lambda_k \end{bmatrix} + \begin{bmatrix} q_k \\ v_k \end{bmatrix}$
$\min F(\mathbf{x}, \rho) = f(\mathbf{x}) + \rho P(\mathbf{x})$
$\begin{cases} \min & \frac{1}{2}\mathbf{q}^T[\nabla^2_{x,x}L(\mathbf{x}_k, \lambda_k)]\mathbf{q} + \mathbf{q}^T[\nabla_x L(\mathbf{x}_k, \lambda_k)] \\ \text{Sujeto a:} & [\nabla H(\mathbf{x}_k)]^T\mathbf{q} + H(\mathbf{x}_k) = \mathbf{0} \end{cases}$

Ideas clave

6.1 Introducción

En este tema, afrontaremos, desde un punto de vista algorítmico, los problemas de optimización con restricciones. En el tema anterior hemos derivado condiciones necesarias y suficientes para la existencia de soluciones locales de estos problemas. Para hacerlo, no hemos perdido de vista el caso sin restricciones ya que, esencialmente, la estrategia ha sido reducir el problema con restricciones a otro equivalente sin restricciones. En este capítulo, también tomaremos ese camino.

Recordamos que, cuando consideramos algoritmos para encontrar el óptimo de una función no lineal sin restricciones, partiendo de una condición inicial, intentamos reducir iterado a iterado, la el valor de la función objetivo. Esto implica resolver dos subproblemas.

1. Calcular una dirección de búsqueda $\mathbf{d}$,
2. Calcular un paso $t > 0$ para obtener un nuevo punto con un menor valor de la función objetivo.

Aplicaremos el mismo esquema para el caso de optimización con restricciones. La intuición nos dice que el principal inconveniente del esquema anterior es que la dirección de búsqueda $\mathbf{d}$ y el paso t deben ser tales que el nuevo punto pertenezca a la región de soluciones factibles. Esto implica que, en cada nuevo iterado, debemos preocuparnos de que la solución siga siendo factible además de que el valor de la función objetivo decrezca.

En la práctica se pueden esbozar algoritmos que no cumplan con ese requerimiento si el criterio de convergencia también tiene en cuenta la condición para la restricción. Esto es, el algoritmo no cumple la condición de parada hasta que las restricciones se cumplen con una cierta tolerancia.

6.2 Objetivos

En realidad, los objetivos para este tema se centran básicamente en lo ya expuesto, es decir, tratar de hallar una dirección de descenso que permita ir disminuyendo en cada iterado el valor de la función objetivo y, por otra parte, el paso adecuado trabaja justamente en que el descenso se de en los mejores términos, evitando pasar por zonas de factibilidad sin ser detectadas.

Trabajar en esta dirección trae como consecuencia directa el alto costo computacional que conlleva la evaluación constante en la función objetivo, llegando inclusive conseguir métodos que no cumplan con el descenso, por estar justamente en la comparación exhaustiva con las restricciones.

6.3 Métodos de Penalización

Empezamos estudiando una categoría general de métodos, llamados de **penalización**. La idea detrás de estos métodos es, a partir de un problema con restricciones, crear un problema sin restricciones y una **función de penalización** que agregue valores grandes (valores de penalización) a los puntos que no verifican las restricciones. Los valores de penalización se suman a los de la función objetivo, de manera que minimizar ambas funciones debería arrojar buenos resultados para el problema con restricciones.

Hay una cierta libertad en la elección de penalización por no verificar las restricciones. Esto implica que, en esta libertad, uno tome la decisión de no penalizar lo suficiente el

hecho de no cumplir con las restricciones y que el proceso se termine con una solución no factible. En tal caso, se puede automatizar una segunda resolución del problema incrementando la penalización.

La gran ventaja de este punto de vista es su sencillez. La desventaja principal es que la solución que da el método solamente es factible en el límite. Esto es, si el método termina de forma prematura, la solución no es factible.

Consideramos un problema de restricciones de igualdad.

$$\begin{cases} \text{mín} & f(\boldsymbol{x}) \\ \text{Sujeto a:} & H(\boldsymbol{x}) = \boldsymbol{0} \end{cases}$$

Nuestra intención es crear una función de penalización P y reducir el problema a la minimización de una función sin restricciones

$$\boxed{F(\boldsymbol{x}, \rho) = f(\boldsymbol{x}) + \rho P(\boldsymbol{x})}$$

Aquí, $\rho > 1$ será el llamado **parámetro de penalización**. Existe una cantidad infinita de maneras distintas de escoger la función P y cada una de ellas tendrá un comportamiento distinto, esto es, resultará en un mejor o peor método de resolución. Una manera sencilla de construir funciones de penalización es considerar la norma del error cometido en las ecuaciones de restricción.

Sin considerar, aún, qué elección tomamos para la función de penalización podemos esbozar un algoritmo que nos lleve a la solución del problema.

Supongamos, pues, que P es una función de penalización y consideramos el problema sin restricciones engendrado por la función: $F(\boldsymbol{x}, \rho) = f(\boldsymbol{x}) + \rho P(\boldsymbol{x})$. Las condiciones de inicio serán: una condición inicial $\boldsymbol{x}_0$, $\rho_0 = 1$. Es habitual fijar una tolerancia especifica para las restricciones $\varepsilon_r > 0$. De manera que si $\|H(\boldsymbol{x})\| < \varepsilon_r$, consideremos $\boldsymbol{x}$ una solución factible.

Partiendo de $k = 0$, se tiene que el algoritmo sigue los siguientes pasos:

1. Comprobamos si tenemos una solución del problema. Esto es: si el gradiente de la función objetivo es nulo y si las restricciones se cumplen. Si tal cosa ocurre, se termina el programa. En caso contrario se avanza al siguiente paso.

2. Solucionamos el problema de minimización sin restricciones dado por F. Aquí, en principio, cualquier método es válido. Eso sí, hay que tener en cuenta que la convergencia de ciertos métodos se puede ver la forma de la función F.

3. Actualizamos la iteración. Eso significa aumentar el número de iterados $k \to k+1$, tomamos $\mathbf{x}_1$ como la solución del problema resuelto en el paso anterior, actualizamos $\rho_{k+1} = \beta\rho_k$, donde $\beta > 1$. Volvemos a **1**.

Ejemplo 1. Penalización

Consideramos el siguiente problema

$$\begin{cases} \min\limits_{(x,y)x\in\mathbb{R}^2} & -xy \\ \text{Sujeto a:} & x + 2y - 4 = 0 \end{cases}$$

Paso 1 Consideramos como función de penalización la función $\frac{1}{2}H^2$, donde $H(x, y) = x - 2y - 4$. Esto es, reducimos el problema al estudio de la familia de problemas de minimización sin restricciones

$$\text{minimizar } F(\mathbf{x}, \rho) = -xy + \frac{1}{2}\rho(x + 2y - 4)^2.$$

Paso 2 Encontramos los candidatos a óptimos resolviendo el sistema $\nabla F = 0$. Esto es:

$$\begin{cases} -y + \rho(x - 2y - 4) = 0 \\ -x - 2\rho(x - 2y - 4) = 0 \\ H(x, y) = 0 \end{cases}$$

Paso 3 Podemos resolver este sistema de ecuaciones en función de ρ. Esto es

$$x(\rho) = \frac{8\rho}{4\rho - 1}, \quad y(\rho) = \frac{4\rho}{4\rho - 1}.$$

Evidentemente, este solución es singular para $\rho = 1/4$, lo cual no es relevante en esta ocasión ya que siempre se elegirá $\rho > 1$. Notamos que la solución no es factible, ya que

$$H(x(\rho), y(\rho)) = \frac{4}{4\rho - 1}.$$

Tomando $\rho \to \infty$ tenemos que $x(\rho) \to 2$ y $y(\rho) \to 1$.

Para comprobar que en efecto esto es así, construimos la función lagrangiana:

$$L(x, y, \lambda) = -xy + \lambda(x - 2y - 4)$$

y considerando el sistema:

$$\begin{cases} \dfrac{\partial L}{\partial x} = -y + \lambda = 0 \\ \dfrac{\partial L}{\partial y} = -x + 2\lambda = 0 \\ \dfrac{\partial L}{\partial \lambda} = x + 2y - 4 = 0 \end{cases} \rightarrow \begin{array}{c} \boxed{y = \lambda} \\ \boxed{x = 2\lambda} \\ \boxed{\lambda = 1} \end{array} \rightarrow \boxed{(x, y) = (2, 1)}$$

6.4 Gradiente reducido

La siguiente familia de métodos que vamos a explorar son los métodos del gradiente reducido. A diferencia de los métodos de penalización, estos métodos tratan de preservar la factibilidad en cada iterado. Esta estrategia redunda en varias ventajas.

En primer lugar, si cada iterado estima una solución factible, el algoritmo se puede detener antes de haber alcanzado la convergencia y la aproximación obtenida aún puede ser útil. Por otro lado, es más fácil medir la convergencia ya que en cada iterado uno puede utilizar directamente la función objetivo (en vez de una función que contiene

la penalización). La desventaja de este método es el coste computacional: En efecto, tener que asegurar que cada iterado se encuentra dentro de la región de soluciones factibles conlleva una serie de evaluaciones de las funciones no lineales que determinan las restricciones. Para este método vamos a considerar, otra vez, un problema de restricción con igualdades:

$$\begin{cases} \text{mín} & f(\boldsymbol{x}) \\ \text{Sujeto a:} & H(\boldsymbol{x}) = \boldsymbol{0} \end{cases}$$

Ahora utilizamos la regla de los multiplicadores de Lagrange para construir una función Lagrangiana

$$L(\boldsymbol{x}, \lambda) = f(\boldsymbol{x}) - \sum_{i=1}^{p} \lambda_i H_i(\boldsymbol{x}).$$

Este es un problema de minimización sin restricciones, en particular podemos utilizar un esquema de Newton para tratar de encontrar un óptimo.

$$\begin{bmatrix} \boldsymbol{x}_{k+1} \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} \boldsymbol{x}_k \\ \lambda_k \end{bmatrix} + \begin{bmatrix} q_k \\ \nu_k \end{bmatrix}.$$

Aquí, el vector corrector $(q_k, \nu_k)^t$ es la solución del siguiente sistema lineal:

$$\begin{pmatrix} \nabla^2_{x,x} L(\boldsymbol{x}_k, \lambda_k) & -DH(\boldsymbol{x}_k) \\ -DH(\boldsymbol{x}_k)^t & 0 \end{pmatrix} \begin{pmatrix} q_k \\ \nu_k \end{pmatrix} = \begin{pmatrix} -\nabla_x L(\boldsymbol{x}_k, \lambda_k) \\ H(\boldsymbol{x}_k) \end{pmatrix}.$$

Sea Z_k una matriz construida con una base del núcleo de $DH(\boldsymbol{x}_k)^t$ y Y_k una matriz construida con una base del núcleo de $DH(\boldsymbol{x}_k)$. Podemos separar la dirección de búsqueda q_k como

$$q_k = Z_k q_z + Y_k q_y,$$

donde p_z es la solución del sistema

$$Z_k^t [\nabla^2_{xx} L(\boldsymbol{x}_k, \lambda_k)] Z_k q_z = -Z_k^t \nabla_x L(\boldsymbol{x}_k, \lambda_k).$$

La dirección de búsqueda q_y queda determinada imponiendo que el siguiente iterado (esto es, la siguiente aproximación de la solución) sea factible: $H(x_{k+1}) = 0$. Como

$\mathbf{x}_{k+1} = \mathbf{x}_k + p_k$, tenemos la condición

$$H(\mathbf{x}_k + Z_k p_z + Y_k p_y) = 0.$$

Esto es, de hecho, un sistema de ecuaciones no lineales con p ecuaciones y las p variables que determinan p_y (el hecho de que este sistema tenga solución única depende de que la diferencial $DH(\mathbf{x}_k)$ tenga rango máximo, que es una hipótesis que ya hemos discutido como necesaria en el tema anterior). Para resolver este sistema, se necesita un método de resolución de ecuaciones no lineales. Por ejemplo, el método de Newton.

Ejemplo 2. Gradiente Reducido

Vamos a aplicar el método del gradiente reducido al siguiente problema de minimización con restricciones de igualdad:

$$\begin{cases} \displaystyle\min_{(x,y)\in\mathbb{R}^2} & e^{3x} + e^{-4y} \\ \text{Sujeto a:} & x^2 + y^2 - 1 = 0 \end{cases}$$

Paso 1 Utilizamos la condición inicial $\mathbf{x}_0 = (-1, 1)^t$. Esta condición inicial no es, de hecho, factible.

Nota: El método se encargará de corregir este detalle para la siguiente iteración.

Paso 2 Las siguientes cantidades tienen que ser evaluadas en $\mathbf{x}_0$ para encontrar las direcciones de búsqueda del primer iterado:

$$\nabla f(x,y) = \begin{pmatrix} 3e^{3x} \\ -4e^{-4y} \end{pmatrix}, \quad \nabla^2 f(x,y) = \begin{pmatrix} 9e^{3x} & 0 \\ 0 & 16e^{-4y} \end{pmatrix},$$

$$H(x,y) = x^2 + y^2 - 1, \quad \nabla H(x,y) = \begin{pmatrix} 2x \\ xy \end{pmatrix}, \quad \nabla^2 H(x,y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}.$$

Veamos,

$$\nabla f \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3e^{-3} \\ -4e^{-4} \end{bmatrix} = \begin{bmatrix} 0.14936 \\ -0.07326 \end{bmatrix}$$

$$\nabla^2 f \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 9e^{-3} & 0 \\ 0 & 16e^{-4} \end{bmatrix} = \begin{bmatrix} 0.44808 & 0 \\ 0 & 0.29305 \end{bmatrix}$$

Además,

$$\nabla H \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 2 \end{bmatrix} \quad \text{y} \quad \nabla^2 H \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Paso 3 Ahora utilizamos la regla de los multiplicadores de Lagrange. Encontramos λ_0 que sea solución del problema de minimización unidimensional:

$$\text{minimizar } \|\nabla f(\mathbf{x}_k) - \lambda \nabla H(\mathbf{x}_k)\|_2^2, \;\; \mathbf{x}_k = \mathbf{x}_0.$$

En efecto, tomando $\alpha = 0.14936$ y $\beta = -0.07326$, se tiene

$$\text{mín } (\alpha + 2\lambda)^2 + (\beta - 2\lambda)^2 \;\; \rightarrow \;\; \lambda = \frac{\beta - \alpha}{4} = -0.055655$$

Paso 4 Con este valor, podemos calcular las cantidades

$$\nabla_{\mathbf{x}} L = \nabla f - \lambda \nabla H = \begin{bmatrix} 0.14936 \\ -0.07326 \end{bmatrix} + 0.055655 \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 0.03805 \\ 0.26067 \end{bmatrix}$$

y además,

$$\begin{aligned} \nabla^2_{\mathbf{x},\mathbf{x}} L = \nabla^2 f - \lambda \nabla^2 H &= \begin{bmatrix} 0.44808 & 0 \\ 0 & 0.29305 \end{bmatrix} + 0.055655 \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 0.0.55939 & 0 \\ 0 & 0.40436 \end{bmatrix} \end{aligned}$$

Paso 5 Recordamos que $\nabla H = (2x, 2y) = (B, N)$. Llamando $B = 2x$ y $N = 2y$, podemos calcular:

$$Z_k = -B^{-1}NI = \begin{bmatrix} -\frac{y}{x} \\ 1 \end{bmatrix}$$

Nota: En realidad hemos considerado la ecuación $Bx + Ny = 0$, hemos despejado x en función de y y hemos otorgado $y = 1$.

Paso 5 La imagen es todo $\mathbb{R}^2$

$$Y_k = \frac{1}{\sqrt{x^2 + y^2}} \begin{bmatrix} x \\ y \end{bmatrix}$$

Paso 6 Tenemos que $\mathbf{x}_0 = (-1, 1)^T$, luego

$$Z_0 = \begin{bmatrix} -\frac{y}{x} \\ 1 \end{bmatrix}_{(-1,1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Recordamos que la componente p_z de la dirección de búsqueda es solución de:

$$Z_k^T[\nabla^2_{x,x} L(\mathbf{x}_k, \lambda_k)] Z_x q_z = -Z_k^T \nabla_x L(\mathbf{x}_k, \lambda_k) \ , \ k = 0$$

Tenemos todo lo necesario y haciendo cálculos nos queda:

$$(0.963754)p_z = -0.076099 \ , \ p_z = -0.0078961$$

Paso 7 La otra componente, p_y, es solución de $H(\mathbf{x}_0 + Z_0 p_z + Y_0 p_y) = 0$, donde las cantidades rojas son conocidas:

$$\mathbf{x}_0 + Z_0 p_z + Y_0 p_y$$

Por tanto,

$$\begin{bmatrix} -1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \end{bmatrix} (-0,078961) + \begin{bmatrix} -0.70711 \\ 0.70711 \end{bmatrix} p_y$$

Es decir, tenemos que solucionar la ecuación:

$$(-1.07896 - p_y/\sqrt{2})^2 + (0.92104 + p_y/\sqrt{2})^2 - 1 = 0$$

que tiene dos soluciones:

$$p_y \approx -2.40796 \ , \ p_y \approx -0.420468$$

(Tomamos la segunda). La dirección de búsqueda:

$$p_0 = Z_0 p_z + Y_0 p_y = \begin{bmatrix} 0.218355 \\ -0.376276 \end{bmatrix}$$

Finalmente, el primer iterado es:

$$\mathbf{x}_1 = \mathbf{x}_0 + p_0 = \begin{bmatrix} -0.78164 \\ 0.62372 \end{bmatrix}$$

Notamos que $(-0.781642)^2 + (0.623722)^2 = 0,99999 \approx 1$, es decir, este iterado cumple con las restricciones. ■

6.5 Programación cuadrática secuencial

El último método que vamos a estudiar es muy parecido al anterior. Se trata de obtener la dirección de búsqueda resolviendo un problema de optimización cuadrático y con restricciones lineales. Como viene siendo habitual, consideramos el problema

$$\begin{cases} \text{mín} & f(\mathbf{x}) \\ \text{Sujeto a:} & H(\mathbf{x}) = \mathbf{0} \end{cases}$$

Como en el caso anterior buscamos condiciones necesarias sobre la función Lagrangiana, esto es

$$\nabla L(\boldsymbol{x}, \lambda) = \mathbf{0}.$$

Para encarar este problema, recurrimos, de nuevo al método de Newton. La dirección de búsqueda $(q_k, v_k)^t$, será solución del sistema.

$$\begin{pmatrix} \nabla^2_{x,x} L(\boldsymbol{x}_k, \lambda_k) & -DH(\boldsymbol{x}_k) \\ -DH(\boldsymbol{x}_k)^t & \mathbf{0} \end{pmatrix} \begin{pmatrix} q_k \\ v_k \end{pmatrix} = \begin{pmatrix} -\nabla_x L(\boldsymbol{x}_k, \lambda_k) \\ H(\boldsymbol{x}_k) \end{pmatrix}.$$

Aquí variamos la dirección con respecto al método del gradiente reducido. Simplemente, nos damos cuenta de que este sistema de ecuaciones son las condiciones necesarias de primer orden del siguiente problema:

$$\begin{cases} \text{mín} & \frac{1}{2} q^T [\nabla^2_{x,x} L(\boldsymbol{x}_k, \lambda_k)] \mathbf{q} + \mathbf{q}^T [\nabla_x L(\boldsymbol{x}_k, \lambda_k)] \\ \text{Sujeto a:} & [\nabla H(\boldsymbol{x}_k)]^T \mathbf{q} + H(\boldsymbol{x}_k) = \mathbf{0} \end{cases}$$

Aquí, v_k será el vector de los multiplicadores de Lagrange.